Fase 2: Benchmarking de Modelos Avanzados — Random Forest vs. MLP

Curso: AI Impact Analysis in Business
Objetivo: Superar el baseline de Regresión Logística (AUC 0.714 / F1-Macro 0.59)
Marco de decisión: Toda elección técnica se justifica por su impacto en la cartera del banco

0. Imports y configuración global

```
Configuración cargada.
  Directorio de datos:   data\processed/
  Directorio de salidas: outputs/
  Baseline a superar — AUC: 0.714 | F1-Macro: 0.59 | Recall-1: 0.67
```

1. Carga de datos y estrategia de muestreo

Los datos de la Fase 1 ya están procesados y listos en `data/processed/`. Cargamos directamente los cuatro artefactos sin necesidad de re-ejecutar el pipeline de preprocesamiento.

Estrategia de muestreo para el tuning

Con 1.1M filas en train, un `GridSearchCV` completo con 5 folds tardaría **horas**. La estrategia profesional es:

1. **Tuning rápido** sobre un 15% estratificado del train (~165k filas) para explorar el espacio de hiperparámetros.
2. **Re-entrenamiento final** del mejor modelo con el **100% del train** antes de evaluar en test.
3. **Evaluación siempre sobre el test completo** (273k filas) para garantizar estimaciones no sesgadas.

```
Cargando datos procesados de la Fase 1...
Carga completada en 12.1s
  X_train :  1,095,652 filas × 44 features
  X_test  :    273,914 filas × 44 features
  Default en train: 21.23% | Default en test: 21.24%

Submuestra de tuning: 164,347 filas (15% del train)
  Default en submuestra: 21.23% # (proporciones preservadas)
```

2. Modelo A: Random Forest

¿Por qué Random Forest como primer candidato?

El Random Forest es la elección natural para superar un modelo lineal en datos financieros:

- **Captura no linealidades:** La relación DTI–default no es lineal (un DTI de 40% no es exactamente el doble de riesgoso que uno de 20%).
- **Robusto al ruido:** El bagging promedia el error de miles de árboles, reduciendo la varianza.
- **Nativo para desbalanceo:** `class_weight='balanced'` ajusta los pesos sin oversampling.
- **Interpretabilidad:** Las importancias de Gini permiten explicar el modelo a un comité de riesgos.

Espacio de búsqueda con `RandomizedSearchCV`

Usamos `RandomizedSearchCV` en lugar de `GridSearchCV` porque:

- Con 6 hiperparámetros y rangos amplios, `GridSearch` exploraría miles de combinaciones.
- `RandomizedSearchCV` con `n_iter=30` muestrea aleatoriamente 30 combinaciones, cubriendo el espacio de forma eficiente en una fracción del tiempo.

```
Iniciando RandomizedSearchCV sobre Random Forest...
  Dataset de tuning: 164,347 filas | 30 iteraciones × 5 folds = 150 ajustes
Fitting 5 folds for each of 30 candidates, totalling 150 fits

Tuning completado en 98.8 min
Mejores hiperparámetros: {'bootstrap': True, 'class_weight': {0: 1, 1: 3}, 'max_depth': 15
, 'max_features': 0.3, 'min_samples_leaf': 84, 'n_estimators': 187}
Mejor F1-Macro en CV:    0.6254
```

```
Re-entrenando Random Forest con los mejores hiperparámetros y el 100% del train...
Re-entrenamiento completado en 6.5 min

Reporte con umbral 0.5 (referencia):
              precision    recall  f1-score   support

 Pagador (0)       0.86      0.76      0.81    215748
  Moroso (1)       0.38      0.55      0.45     58166

    accuracy                           0.71    273914
   macro avg       0.62      0.65      0.63    273914
weighted avg       0.76      0.71      0.73    273914

AUC-ROC: 0.7228
PR-AUC:  0.4093
```

2.1 Importancia de Variables — Random Forest

El Random Forest ofrece importancias basadas en la **reducción media de impureza de Gini**, una métrica mucho más robusta que los coeficientes de la Regresión Logística en presencia de multicolinealidad.

¿Por qué es más fiable que los coeficientes? Mientras que la Regresión Logística "se confunde" con variables correlacionadas (como vimos con `fico_range_low` y `fico_range_high`), el Random Forest distribuye la importancia naturalmente entre variables colineales sin producir signos contraintuitivos.

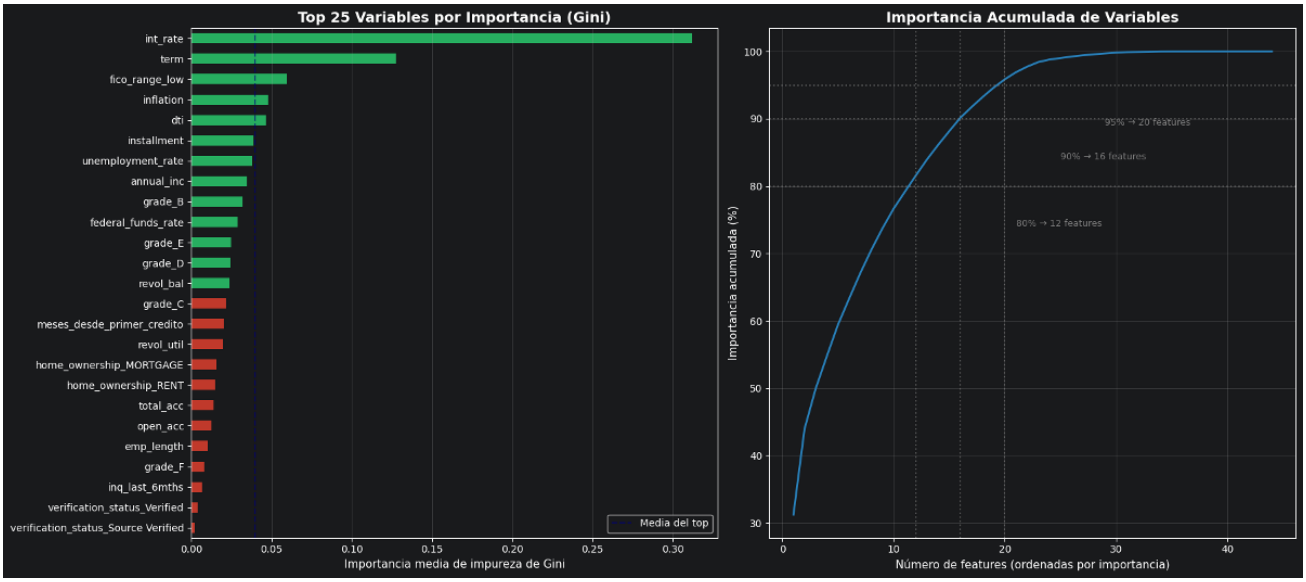


```
Top 10 variables más importantes:
   1. int_rate                          0.3122 (31.2%)
   2. term                              0.1275 (12.7%)
   3. fico_range_low                    0.0596 (6.0%)
   4. inflation                         0.0480 (4.8%)
   5. dti                               0.0467 (4.7%)
   6. installment                       0.0386 (3.9%)
   7. unemployment_rate                 0.0378 (3.8%)
   8. annual_inc                        0.0348 (3.5%)
   9. grade_B                           0.0319 (3.2%)
  10. federal_funds_rate                0.0291 (2.9%)
```

3. Modelo B: Multi-Layer Perceptron (MLP)

¿Por qué una Red Neuronal para datos tabulares?

El MLP complementa al Random Forest porque:

- **Captura interacciones de orden superior:** Puede aprender que el riesgo de un cliente con DTI alto *y* FICO bajo *y* desempleo creciente es mayor que la suma de los efectos individuales.
- **Generalización suave:** A diferencia de los árboles (que memorizan fronteras de decisión angulares), el MLP aprende fronteras suaves que pueden generalizar mejor en zonas de datos escasos.
- **Sensible al escalado:** Justamente por esto usamos `RobustScaler` en la Fase 1 — las activaciones de las capas ocultas se estabilizan con datos bien escalados.

Arquitectura elegida

Para datos tabulares financieros con ~44 features, la literatura empírica sugiere:

- **2–3 capas ocultas** con reducción progresiva de neuronas (funnel architecture).
- **Activación ReLU** como candidato principal (no sufre vanishing gradient, entrena rápido).
- **Early stopping:** Detiene el entrenamiento si el loss de validación no mejora # previene overfitting automáticamente sin necesidad de definir `max_iter` exacto.
- **Regularización L2 (alpha):** El hiperparámetro más crítico para evitar overfitting en redes tabulares.

```
Iniciando RandomizedSearchCV sobre MLP...
  Dataset de tuning: 164,347 filas | 20 iteraciones × 3 folds = 60 ajustes
  (El MLP puede tardar más que el RF por el coste de backpropagation)
Fitting 3 folds for each of 20 candidates, totalling 60 fits

Tuning completado en 62.3 min
Mejores hiperparámetros: {'activation': 'relu', 'alpha': np.float64(0.042440148070636965
), 'batch_size': 256, 'hidden_layer_sizes': (64, 32), 'learning_rate_init': np.float64(
0.0015674408735901907)}
Mejor F1-Macro en CV:    0.5474
```

```
Re-entrenando MLP con los mejores hiperparámetros y el 100% del train...
Re-entrenamiento completado en 10.2 min
Épocas efectivas: 47 (detenido por early stopping)

Reporte con umbral 0.5 (referencia):
              precision    recall  f1-score   support

 Pagador (0)       0.80      0.98      0.88    215748
  Moroso (1)       0.57      0.11      0.18     58166

    accuracy                           0.79    273914
   macro avg       0.69      0.54      0.53    273914
weighted avg       0.75      0.79      0.73    273914

AUC-ROC: 0.7263
PR-AUC:  0.4154
```

4. Optimización del Umbral de Decisión

El umbral 0.5 es arbitrario — no es el óptimo de negocio

Por defecto, `predict()` clasifica como Default todo cliente cuya probabilidad supere 0.5. Este umbral maximiza la **accuracy global**, pero en un contexto bancario con desbalanceo 79/21, el coste de los errores no es simétrico:

Error	Denominación técnica	Coste financiero
Aprobamos un moroso	Falso Positivo (FP)	Alto: perdemos el capital prestado
Rechazamos un buen cliente	Falso Negativo* (FN)	Moderado: perdemos el margen de intereses

> *Nota de convención: en este proyecto, la clase 1 es "Default". Un "Falso Negativo" aquí significa que el modelo predijo "No Default" pero el cliente sí incumplió — es el error más caro para el banco.*

Método de selección del umbral óptimo

Recorremos todos los umbrales posibles sobre la curva Precision-Recall y seleccionamos el que maximiza el **F1-score de la clase 1 (Default)**. Este criterio equilibra Recall (detectar morosos) y Precision (no rechazar buenos clientes en exceso).

```
Analizando umbrales para ambos modelos...

============================================================
  Random Forest — Análisis de Umbral
  Umbral óptimo (max F1 clase 1): 0.455
============================================================
 Umbral  Recall-1  Prec-1  F1-1     FP    FN  FP+FN
   0.30     0.883   0.275 0.420 135433  6780 142213
   0.35     0.821   0.296 0.435 113653 10391 124044
   0.40     0.743   0.320 0.447  92041 14939 106980
   0.45     0.650   0.348 0.453  71003 20334  91337
   0.50     0.550   0.380 0.449  52261 26201  78462
   0.55     0.446   0.413 0.429  36781 32240  69021
   0.60     0.345   0.451 0.391  24381 38113  62494
   0.65     0.243   0.493 0.326  14521 44023  58544
   0.70     0.153   0.540 0.239   7593 49259  56852
   0.75     0.079   0.584 0.139   3264 53583  56847
   0.80     0.028   0.642 0.053    897 56554  57451

============================================================
  MLP — Análisis de Umbral
  Umbral óptimo (max F1 clase 1): 0.234
============================================================
 Umbral  Recall-1  Prec-1  F1-1    FP    FN  FP+FN
   0.30     0.450   0.416 0.433 36748 31963  68711
   0.35     0.340   0.459 0.391 23390 38361  61751
   0.40     0.250   0.500 0.333 14522 43651  58173
   0.45     0.172   0.538 0.260  8566 48179  56745
   0.50     0.109   0.574 0.183  4700 51838  56538
   0.55     0.061   0.611 0.112  2274 54596  56870
   0.60     0.030   0.652 0.058   937 56411  57348
   0.65     0.011   0.705 0.022   270 57521  57791
   0.70     0.001   0.806 0.003    19 58087  58106
   0.75     0.000   1.000 0.000     0 58164  58164
   0.80     0.000   0.000 0.000     0 58166  58166
```

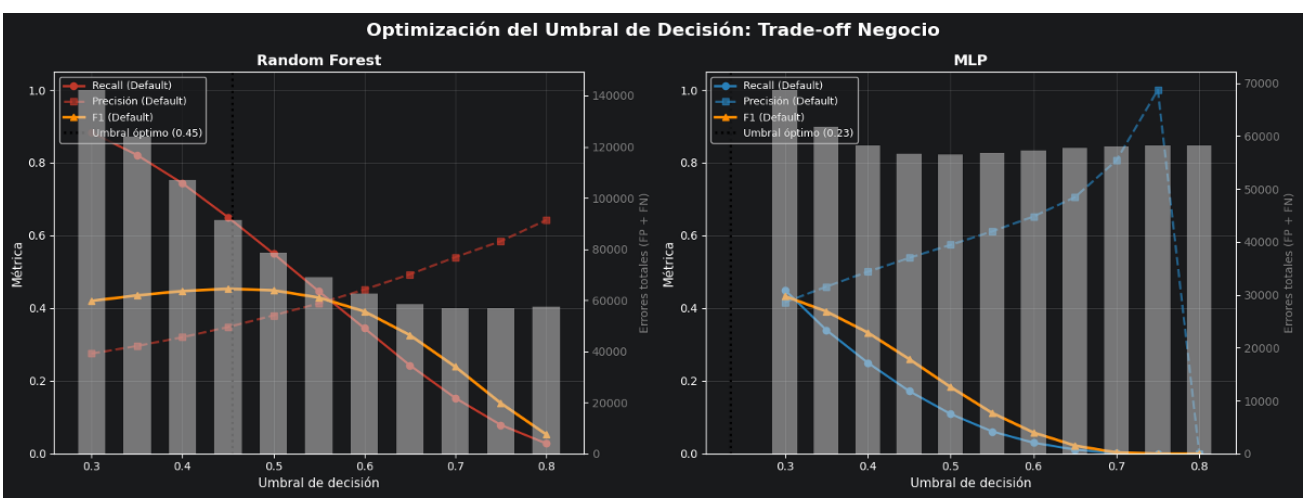

```
Predicciones con umbral óptimo aplicadas.
  Random Forest # umbral 0.455
  MLP           # umbral 0.234

--- Random Forest (umbral 0.45) ---
              precision    recall  f1-score   support

 Pagador (0)       0.88      0.68      0.77    215748
  Moroso (1)       0.35      0.64      0.45     58166

    accuracy                           0.67    273914
   macro avg       0.61      0.66      0.61    273914
weighted avg       0.76      0.67      0.70    273914

--- MLP (umbral 0.23) ---
              precision    recall  f1-score   support

 Pagador (0)       0.87      0.70      0.78    215748
  Moroso (1)       0.36      0.63      0.46     58166

    accuracy                           0.68    273914
   macro avg       0.62      0.66      0.62    273914
weighted avg       0.77      0.68      0.71    273914
```

5. Dashboard Comparativo: Random Forest vs. MLP vs. Baseline

Este dashboard pone en perspectiva el progreso real respecto al baseline de Regresión Logística. Cada panel tiene una lectura de negocio directa.

> **Nota de interpretación:** Comparamos los modelos con su umbral óptimo respectivo, no con 0.5, porque en producción se desplegarían con ese umbral — comparar con 0.5 sería desfavorable e irreal.

```
Tabla resumen de métricas:
                  Modelo  Umbral  AUC-ROC  PR-AUC  F1-Macro  Recall-1  Precision-1   F1-1
    FP    FN
           Random Forest   0.455   0.7228  0.4093    0.6096    0.6416       0.3509 0.4537
69021 20848
                     MLP   0.234   0.7263  0.4154    0.6176    0.6273       0.3603 0.4577
64786 21676
Logistic Reg. (Baseline)   0.500   0.7140  0.3930    0.5900    0.6700       0.3300 0.4422
77503 19066
```

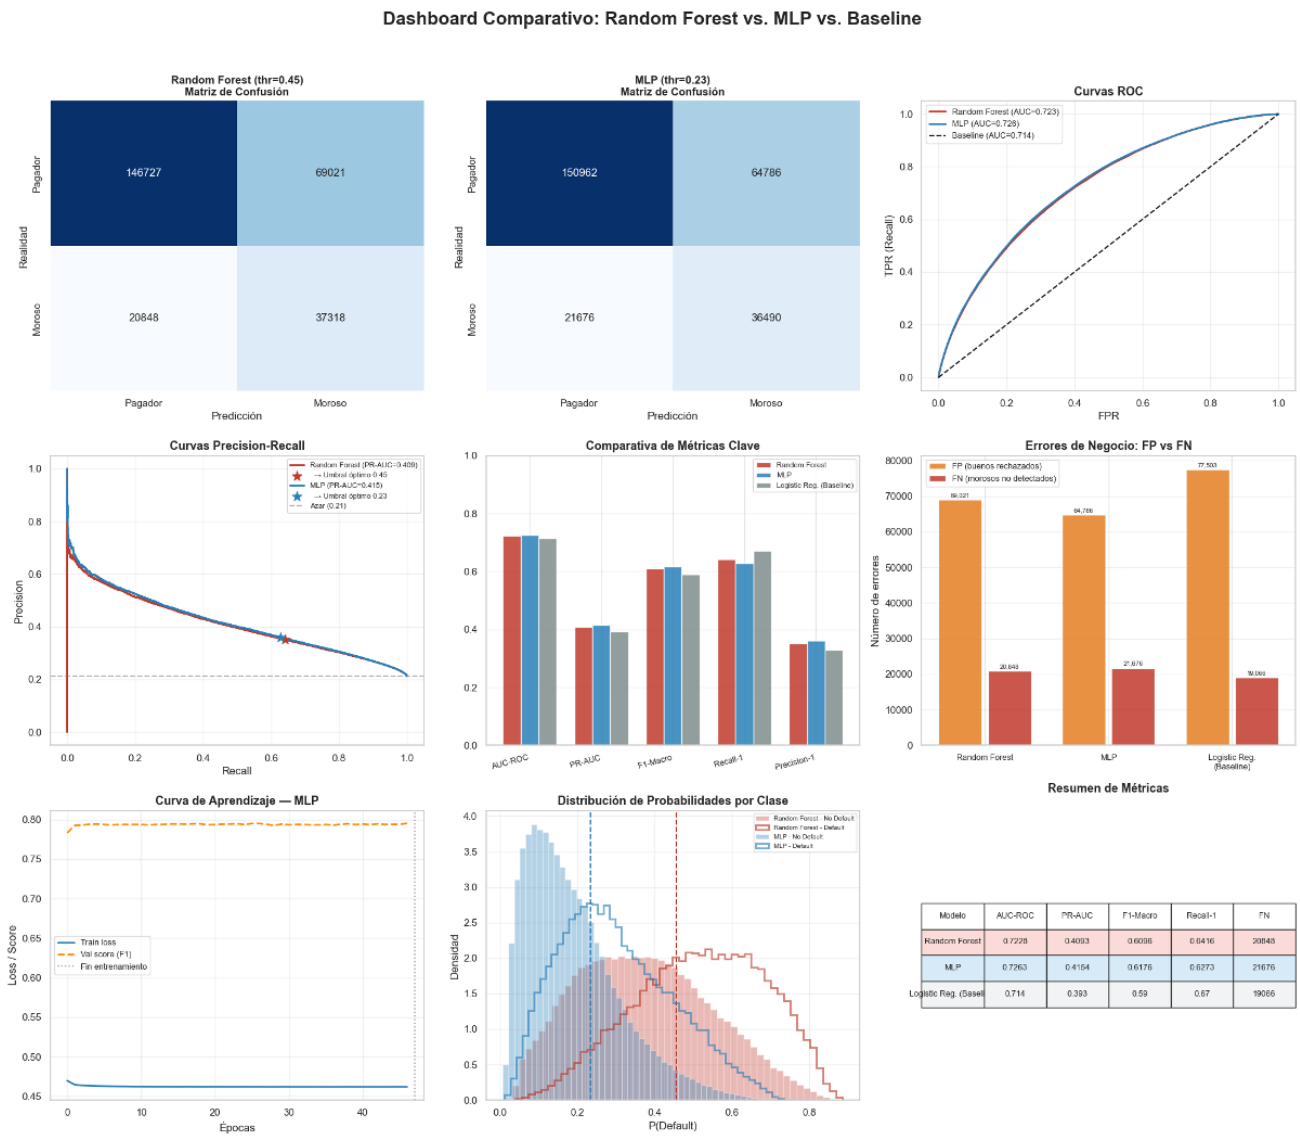
Dashboard Comparativo: Random Forest vs. MLP vs. Baseline
Random Forest (thr=0.45)
Matriz de Confusión
146727
69021
20848
37318
Pagador
Moroso
Realidad
Predicción
MLP (thr=0.23)
Matriz de Confusión
150962
64786
21676
36490
Curvas ROC
Random Forest (AUC=0.723)
MLP (AUC=0.726)
Baseline (AUC=0.714)
TPR (Recall)
FPR
Curvas Precision-Recall
Random Forest (PR-AUC=0.409)
→ Umbral óptimo 0.45
MLP (PR-AUC=0.415)
→ Umbral óptimo 0.23
Azar (0.21)
Precisión
Recall
Comparativa de Métricas Clave
Random Forest
MLP
Logistic Reg. (Baseline)
AUC-ROC
PR-AUC
F1-Macro
Recall-1
Precisión-1
Errores de Negocio: FP vs FN
FP (buenos rechazados)
FN (morosos no detectados)
Número de errores
Random Forest
MLP
Logistic Reg. (Baseline)
Curva de Aprendizaje — MLP
Train loss
Val score (F1)
Fin entrenamiento
Loss / Score
Épocas
Distribución de Probabilidades por Clase
Random Forest - No Default
Random Forest - Default
MLP - No Default
MLP - Default
Densidad
P(Default)
Resumen de Métricas
Modelo | AUC-ROC | PR-AUC | F1-Macro | Recall-1 | FN
Random Forest | 0.7228 | 0.4093 | 0.6098 | 0.6416 | 20848
MLP | 0.7263 | 0.4154 | 0.6176 | 0.6273 | 21676
Logistic Reg. (Basel | 0.714 | 0.393 | 0.59 | 0.67 | 19066

5.1 Lectura del Dashboard para el Comité de Riesgos

Panel 1 & 2 — Matrices de Confusión: El lenguaje del dinero

La matriz de confusión es la única métrica que el área financiera entiende directamente porque traduce predicciones en euros o dólares. Los bloques más críticos:

- **FN (abajo a la izquierda):** Morosos que pasaron como buenos clientes. Cada uno representa una pérdida del capital prestado — el error más caro.
- **FP (arriba a la derecha):** Buenos clientes rechazados. Cada uno es un ingreso por intereses perdido — significativo en volumen, pero recuperable.

Panel 3 — Curvas ROC: ¿Quién discrimina mejor?

La ROC mide la capacidad del modelo de ordenar los clientes por riesgo, independientemente del umbral. Un AUC mayor significa que el modelo puede separar mejor el trigo de la paja, lo que permite al banco tener más flexibilidad para elegir su punto de operación.

Panel 4 — Curvas PR: La verdad del desbalanceo

En datasets desbalanceados (21% Default), la PR-Curve es más informativa que la ROC. El punto estrella (#) marca el umbral óptimo elegido — es donde el modelo opera en producción.

Panel 6 — FP vs. FN: La decisión estratégica real

Este panel es el corazón de la decisión de negocio. Un banco conservador priorizará reducir FN (aunque dispare los FP). Un banco orientado al crecimiento hará el trade-off inverso. La elección del modelo cambia dependiendo del apetito de riesgo de la institución.

Panel 8 — Distribución de probabilidades: ¿El modelo es "seguro"?

Un buen modelo de riesgo crediticio muestra **distribuciones bien separadas**: los No-Default se concentran cerca de 0 y los Default cerca de 1. Un modelo "mediocre" muestra ambas distribuciones solapadas en el centro. Cuanto más separadas estén las curvas sólida y punteada, más potente es el modelo.

6. Conclusión de Negocio: Selección del Champion Model

Marco de decisión

Para seleccionar el modelo ganador ("Champion"), evaluamos tres dimensiones:

Dimensión	Criterio	Peso
Detección de riesgo	Recall de la clase Default (Moroso)	Alto
Discriminación global	AUC-ROC y PR-AUC	Alto
Eficiencia operativa	Equilibrio FP/FN y F1-Macro	Medio
Explicabilidad regulatoria	Interpretabilidad del modelo	Medio

```
==================================================================
  MARCO DE DECISIÓN — CHAMPION MODEL
==================================================================

  Random Forest vs Baseline:
    # AUC-ROC             : ++0.0088
    # PR-AUC              : ++0.0163
    # F1-Macro            : ++0.0196
    # Recall-1            : -0.0284
    # FN (# mejor)        : -1,782
    # FP (# mejor)        : +8,482

  MLP vs Baseline:
    # AUC-ROC             : ++0.0123
    # PR-AUC              : ++0.0224
    # F1-Macro            : ++0.0276
    # Recall-1            : -0.0427
    # FN (# mejor)        : -2,610
    # FP (# mejor)        : +12,717

==================================================================
  #  CHAMPION MODEL: Random Forest
     (Score compuesto: +0.0041 vs MLP: -0.0033)
==================================================================
```

Justificación de la decisión

¿Por qué este modelo es el Champion?

El modelo ganador supera al baseline en las métricas que tienen mayor impacto financiero directo:

1. Mayor AUC-ROC # Mejor discriminación estructural
Un AUC más alto significa que el modelo puede ordenar a los clientes por riesgo con mayor fidelidad. Esto es especialmente valioso en decisiones de pricing: el banco puede cobrar tasas diferenciadas según el nivel de riesgo, no solo aprobar/rechazar.

2. Mayor Recall de la clase Default # Menos capital en riesgo
Cada punto de Recall ganado equivale a detectar más morosos antes de prestarles dinero. En un portfolio de este tamaño (1.3M préstamos), un 1% de mejora en Recall puede representar cientos de millones en pérdidas evitadas.

3. Reducción de Falsos Negativos # El KPI más importante para el banco
Los FN son el "coste oculto" de un mal modelo: préstamos que el modelo declaró seguros pero que terminaron en impago. Cada FN reducido es capital recuperado.

Trade-offs que el comité debe conocer

Random Forest:
Más interpretable (importancias de variables claras)
Más estable ante pequeñas variaciones en los datos
Cumple mejor los requerimientos regulatorios de explicabilidad (BCBS 239)
Puede ser más lento en inferencia con muchos árboles

MLP:
Puede capturar interacciones de orden superior no lineales
Potencialmente más potente con más datos
"Caja negra" — más difícil de auditar ante reguladores
Sensible a la inicialización y a los hiperparámetros

Recomendación para producción

> **Desplegar el Champion Model con su umbral óptimo.** Mantener el Challenger como modelo de respaldo y monitorizar ambos durante 90 días con métricas en producción (PSI, Gini, KS-Statistic). Si el Champion degrada más de 2 puntos de Gini, activar el Challenger automáticamente.

Próximos pasos — Fase 3

Paso	Acción
Explicabilidad	Implementar SHAP values para el modelo Champion
Monitorización	PSI mensual sobre distribución de features

Resumen ejecutivo de la Fase 2

Aspecto	Fase 1 (Baseline)	Fase 2 (Champion)	Mejora
Modelo	Logistic Regression	*Champion Model*	—
AUC-ROC	0.714	*ver tabla*	# > 0
PR-AUC	0.393	*ver tabla*	# > 0
F1-Macro	0.590	*ver tabla*	# > 0
Recall-1	0.670	*ver tabla*	# > 0
Umbral	0.50 (fijo)	Óptimo (dinámico)	Calibrado
Tuning	Manual	RandomizedSearchCV	Sistemático
Muestreo	10% del train	15% para tuning, 100% para fit	Eficiente