PREDICCIÓN DE RIESGO DE CRÉDITO

LendingClub Credit Risk Modelling

Informe Técnico

Evolución de Modelos: Logistic Regression → Random Forest → LightGBM con Correcciones Metodológicas

Curso: AI Impact Analysis in Business

Prof. Carlos Lastras · Marzo 2026

Dataset: LendingClub (2007–2018) · 2.26M préstamos · 4 Fases de modelado

2.26M	17.2%	0.6994	0.907
Préstamos en el dataset	Tasa de Default (OOT)	AUC-ROC Final (OOT)	Disparate Impact Ratio

Tabla de Contenidos

Tabla de Contenidos.....1

Resumen Ejecutivo 1

1. Definición del Problema de Negocio 1

1.1 La Asimetría del Riesgo Crediticio.....1

1.2 Marco Regulatorio y Restricciones de Producción.....1

2. Datos y Preprocesamiento 1

2.1 El Dataset LendingClub 1

2.2 Definición del Target — La Variable a Predecir 1

2.3 Ingeniería de Características 1

2.4 Enriquecimiento Macroeconómico FRED con Corrección de Leakage.....1

2.5 Gestión de la Multicolinealidad 1

3. Marco de Métricas — Por qué Accuracy No Sirve.....1

4. Fase 1 — Regresión Logística: El Baseline Regulatorio 1

4.1 Justificación del Baseline.....1

4.2 Hallazgos de Variables 1

4.3 Ajuste del Umbral.....1

5. Fase 2 — Random Forest vs. MLP: Benchmarking.....1

5.1 Random Forest — Justificación.....1

5.2 Top 10 Variables por Importancia Gini — Random Forest 1

5.3 Red Neuronal MLP — Benchmark y Descarte Justificado 1

6. Fase 3 — LightGBM con Feature Engineering Avanzado 1

6.1 Por qué LightGBM y no XGBoost 1

6.2 Optimización con Optuna — Fase 3 (Split Aleatorio).....1

6.3 Análisis SHAP Fase 3 — Top 3 Drivers del Default.....1

7. Fase 4 — Correcciones Metodológicas Críticas 1

7.1 FIX #1 — Out-Of-Time Split (Corrección de Leakage Temporal).....1

7.2 FIX #4 & #6 — Performance Window de 18 Meses.....1

7.3 FIX #2 — Función de Coste Financiero Dinámico en Optuna 1

7.4 FIX #5 — Calibración Platt Scaling.....1

7.5 FIX #7 — Auditoría Fair Lending (Disparate Impact) 1

8. Análisis SHAP F4 — Explicabilidad Regulatoria (SR 11-7 / BCBS 239).....1

8.1 Por qué SHAP y no Importancias Gini Nativas 1

8.2 Evolución de Drivers: Fase 3 → Fase 4 1

8.3 Interpretación del SHAP Summary Plot F4 1

8.4 SHAP Waterfall — Auditoría de Cliente Individual 1

9. Benchmark Evolutivo Completo (F1 → F4).....1

9.1 Análisis Comparativo F3 vs. F4 — Más allá del Coste Neto 1

10. Impacto Real en Producción — Proyección de Negocio 1

10.1 Escenario de Referencia — Cartera Bancaria Tipo 1

10.2 Valor Real del Modelo F4 — Dimensiones No Capturadas por el Coste Neto 1

10.3 ROI Estimado de la Implementación 1

10.4 Salvaguardas Operativas — Sostenibilidad del Modelo en Producción.....1

11. Conclusiones y Recomendaciones Finales 1

11.1 Conclusiones Técnicas 1

11.2 Limitaciones y Error Irreducible 1

Resumen Ejecutivo

Este documento consolida el ciclo de vida completo de un modelo de Machine Learning para la predicción de riesgo de crédito sobre datos reales de LendingClub (2007–2018). El proyecto evolucionó en cuatro fases técnicas progresivas, desde una regresión logística de referencia hasta un pipeline LightGBM con múltiples correcciones metodológicas críticas. Cada decisión está fundamentada en criterios de negocio bancario, cumplimiento regulatorio y rigor estadístico.

El objetivo central es identificar anticipadamente a clientes con alta probabilidad de impago antes de que el banco conceda el préstamo, minimizando la pérdida de capital (Falsos Negativos) sin asfixiar la concesión de crédito a clientes solventes (Falsos Positivos). La asimetría de costes entre estos dos tipos de error determina todas las decisiones técnicas del pipeline.

Fase	Modelo	AUC-ROC	PR-AUC	F1-Macro	Recall-1	Split
F1	Logistic Regression (Baseline)	0.714	0.385	0.580	0.65	Aleatorio
F2	Random Forest F2	0.723	0.409	0.625	0.64	Aleatorio
F3	LightGBM	0.7335	0.427	0.640	0.72	Aleatorio*
F4	**LightGBM OOT (thr=0.39)**	**0.6994**	**0.3147**	**0.5534**	**0.14**	**OOT 2017-18**

(*) El AUC 0.7335 de la Fase 3 fue obtenido con split aleatorio que introduce data leakage temporal. El valor OOT de 0.6994 de la última versión es el único auditable y comparable con entornos de producción real.

Conclusión Ejecutiva

El modelo LightGBM F4, con correcciones metodológicas completas (OOT split, Performance Window 18m, FRED con lag de 2 meses, calibración Platt Scaling, función de coste dinámica en dólares, auditoría de equidad Fair Lending y explicabilidad SHAP), constituye el pipeline de referencia para producción bancaria.

Con un AUC prospectivo de 0.6994 en datos out-of-time (2017-2018), una tasa de aprobación equitativa entre estados (DIR = 0.907, por encima del umbral regulatorio de 0.80 de la regla 4/5), y un coste financiero dinámico optimizado, el modelo cumple los requisitos técnicos, regulatorios y de negocio para su despliegue en una institución financiera de primer nivel.

1. Definición del Problema de Negocio

1.1 La Asimetría del Riesgo Crediticio

LendingClub es la mayor plataforma de préstamos peer-to-peer de Estados Unidos. Su modelo de negocio conecta inversores con prestatarios, actuando como intermediario. La viabilidad del sistema depende de estimar con precisión la probabilidad de que un cliente devuelva el préstamo. Un error sistemático destruye la confianza de los inversores y puede llevar a la insolvencia de la plataforma.

El problema central es la asimetría de costes: los dos tipos de error posible no tienen el mismo impacto financiero. Esta asimetría determina todas las decisiones técnicas del proyecto.

Tipo de Error	Denominación	Ejemplo Real	Coste Financiero	Impacto
Falso Negativo (FN)	Aprobamos a un moroso	Préstamo de $15,000 a cliente que no paga	Pérdida total del capital	**CRÍTICO**
Falso Positivo (FP)	Rechazamos a un buen cliente	Se pierde el margen de intereses (~$2,000)	Lucro cesante	**MODERADO**

1.2 Marco Regulatorio y Restricciones de Producción

Cualquier modelo de riesgo crediticio que pretenda ser desplegado en producción bancaria enfrenta restricciones que van más allá del rendimiento estadístico puro:

- Explicabilidad regulatoria (BCBS 239 / SR 11-7): Los marcos de la Reserva Federal exigen que los modelos de riesgo sean auditables. Un comité de riesgos debe poder responder: '¿Por qué se rechazó a este cliente?' La elección de SHAP sobre importancias Gini nativas responde directamente a este requisito.
- Fair Lending (Regla de los 4/5 - EEOC): El Disparate Impact Ratio (DIR) entre grupos geográficos debe mantenerse por encima de 0.80. Un DIR inferior abre la puerta a reclamaciones por discriminación algorítmica (Redlining).
- Desbalanceo de clases: Solo el 17-21% de los préstamos terminan en default. Un modelo que predijera siempre 'buen pagador' obtendría 79%+ de accuracy con utilidad nula. La accuracy es una métrica prohibida en este contexto.
- Contexto temporal: Un préstamo emitido en 2007 (pre-Lehman) no es equivalente a uno de 2017. Ignorar el ciclo económico produce un modelo ciego al contexto macroeconómico.
- Data Leakage: Usar información del futuro para entrenar el modelo es el error más grave en modelado temporal. El split aleatorio mezcla datos de distintas épocas, creando la ilusión de un buen modelo que fracasa en producción.

2. Datos y Preprocesamiento

2.1 El Dataset LendingClub

El dataset contiene 2,260,701 préstamos con 151 variables, cubriendo el período 2007–2018. Para este proyecto se seleccionaron 23 columnas con poder predictivo relevante, evitando la carga de variables redundantes o de baja calidad predictiva.

2.2 Definición del Target — La Variable a Predecir

La variable loan_status contiene múltiples categorías. La definición del target requiere una decisión de negocio explícita:

Estado del Préstamo	Target Asignado	Justificación de Negocio
Fully Paid	**0 — No Default**	Crédito saldado: el banco recuperó capital e intereses.
Charged Off	**1 — Default**	Pérdida real: el banco ha amortizado la deuda.
Default	**1 — Default**	Impago declarado formalmente.
Late (31-120 days)	**1 — Default**	Morosidad grave: pérdida inminente y probable.
Current (< 18m vida)	**EXCLUIDO (NaN)**	Resultado final incierto: incluirlos introduce ruido. Se reintegran en la F4 con Performance Window.
Current (>= 18m vida)	**0 — No Default (F4)**	FIX #6: Clientes que superaron la ventana de desempeño de 18 meses se etiquetan como buenos pagadores.

2.3 Ingeniería de Características

Se crearon variables compuestas con hipótesis económicas concretas que los modelos previos no podían capturar:

Variable Nueva	Fórmula	Hipótesis Económica
payment_to_income_ratio	installment / (annual_inc / 12)	KRI más importante en banca: fracción del salario mensual destinada al préstamo. No importa cuánto gane el cliente, sino cuánto le queda.
real_rate_impact	int_rate / (inflation + ε)	Un préstamo al 15% en entorno de 8% de inflación tiene coste real muy diferente que en un entorno deflacionario.

fico_average	(fico_low + fico_high) / 2	Elimina la redundancia de correlación 1.00 entre ambas variables. Señal limpia del historial crediticio.
debt_burden_score	dti × installment	Producto del nivel de endeudamiento relativo y la presión mensual absoluta. DTI=30 con cuota $2,000 es muy distinto a DTI=30 con cuota $200.
meses_desde_primer_credito	issue_d - earliest_cr_line (en meses)	Proxy de experiencia crediticia. Un cliente con 15 años de historial ha sobrevivido al menos una crisis económica.
unemployment_roll3m	Rolling mean de desempleo 3m	Un mes malo de desempleo puede ser ruido. Una tendencia de 3 meses al alza es una señal inequívoca de deterioro en la capacidad de pago.

2.4 Enriquecimiento Macroeconómico FRED con Corrección de Leakage

Esta es la decisión de ingeniería de datos más relevante del proyecto. Los datos de LendingClub contienen únicamente una fotografía estática del cliente en el momento de la solicitud. Sin embargo, el riesgo de crédito depende también del momento del ciclo económico.

FIX #3 — Rezago de 2 Meses en Variables FRED (Corrección de Leakage Macroeconómico)

Problema original: Las variables FRED se cruzaban con el mismo mes de la solicitud, lo que constituye leakage macroeconómico. El FRED publica los datos con 45-60 días de retraso. Un banco real no tiene acceso a los datos de mayo el día 1 de mayo.

Solución aplicada: Se aplica un lag de 2 meses (shift(2)) a las series CPI, Federal Funds Rate y Unemployment Rate antes del merge con los préstamos. Adicionalmente, se calculan medias móviles de 3 meses (rolling mean) y el delta de desempleo a 3 meses (delta_unemployment_3m) para capturar tendencias del ciclo económico.

Resultado: El préstamo de mayo se cruza con el desempleo de marzo, replicando exactamente la información disponible en el sistema de riesgos del banco en el momento de la decisión.

2.5 Gestión de la Multicolinealidad

Variables	Correlación	Problema	Solución Aplicada

fico_range_low / fico_range_high	1.00	Información idéntica: redundancia total	Crear fico_average; eliminar ambas originales
loan_amnt / installment	0.95	La cuota es función del monto: señal duplicada	Conservar installment (presión mensual directa)
inflation / unemployment_rate	-0.87	Curva de Phillips: relación estructural de la economía	Mantener ambas — reflejo económico real, no artefacto

3. Marco de Métricas — Por qué Accuracy No Sirve

La elección de métricas no es un detalle técnico: es una decisión estratégica con implicaciones financieras directas. Un modelo que predijera siempre 'buen pagador' obtendría 79% de accuracy, pero no detectaría ningún moroso, y sus pérdidas serían catastróficas.

Métrica	Definición	Rol en este Proyecto
Accuracy	Aciertos / Total	**DESCARTADA:** Engaña con clases desbalanceadas (79/21).
Recall (clase 1)	TP / (TP + FN)	**USO PRINCIPAL:** Mide cuántos morosos detectamos. Un FN = capital perdido.
F1-Macro	Promedio F1 ambas clases	**MÉTRICA PRINCIPAL (F1-F3):** Da igual peso a ambas clases sin importar su tamaño.
AUC-ROC	Área bajo curva ROC	**DISCRIMINACIÓN GLOBAL:** Probabilidad de que el modelo ordene bien moroso vs pagador.
PR-AUC	Área bajo curva Precision-Recall	**MÁS HONESTO en desbalanceo:** El azar tiene PR-AUC = 0.21 (no 0.50).
Coste Financiero ($)	FN×loan_amnt + FP×intereses	**OBJETIVO F4:** Optimiza directamente el P&L del banco con dólares reales por préstamo.

4. Fase 1 — Regresión Logística: El Baseline Regulatorio

4.1 Justificación del Baseline

La Regresión Logística no es el modelo más potente, pero tiene una razón de ser irrenunciable en el contexto regulatorio bancario. Los marcos BCBS/EBA para modelos internos de riesgo (IRBA) exigen que la institución sea capaz de explicar matemáticamente sus decisiones. La Regresión Logística ofrece coeficientes interpretables directamente como log-odds: 'un incremento de 1 punto en el DTI multiplica las probabilidades de default por e^0.03 = 1.03'. Esto es exactamente lo que un regulador necesita escuchar.

Además, el baseline establece la barra mínima que cualquier modelo más complejo debe superar para justificar su mayor opacidad y coste computacional.

0.714	0.393	0.580	0.65
AUC-ROC	PR-AUC	F1-Macro	Recall Morosos (thr=0.50)

4.2 Hallazgos de Variables

El gráfico de coeficientes de la Regresión Logística reveló la primera 'escena del crimen' técnica: la multicolinealidad entre loan_amnt e installment produce un efecto paradójico. La cuota mensual (installment) aparece como variable de riesgo, pero el monto total del préstamo (loan_amnt) aparece como variable protectora. Esto es matemáticamente coherente pero económicamente absurdo: sugerir que pedir préstamos más grandes reduce el riesgo no puede presentarse ante un comité de riesgos.

Los grados de riesgo de LendingClub (grade_D, grade_E, grade_C) dominan la importancia del modelo, revelando una fuerte dependencia del scoring interno de la plataforma. Esta dependencia será corregida en las fases posteriores.

4.3 Ajuste del Umbral

El umbral por defecto de 0.50 no es óptimo para el contexto bancario. Este umbral maximiza la accuracy global, pero en un banco el coste de los errores es asimétrico. El análisis de la curva F1 vs. umbral determinó que desplazarse hacia valores de 0.35-0.40 permite capturar significativamente más morosos a un coste marginal de lucro cesante asumible.

5. Fase 2 — Random Forest vs. MLP: Benchmarking

5.1 Random Forest — Justificación

El Random Forest es la elección natural para superar un modelo lineal en datos financieros por cuatro razones concretas: captura no linealidades (la relación DTI-default no es lineal), es robusto al ruido mediante bagging, gestiona el desbalanceo de clases nativamente con class_weight='balanced', y ofrece importancias de Gini interpretables ante un comité de riesgos.

Hiperparámetro	Valor Óptimo	Justificación de Negocio
n_estimators	187 árboles	Balance entre poder predictivo y tiempo de inferencia en producción.
max_depth	15	Evita overfitting en zonas de datos escasos; permite capturar interacciones complejas.
max_features	0.30 (30%)	Decorrelaciona los árboles: cada uno ve solo el 30% de features, reduciendo varianza.
class_weight	{0:1, 1:3}	Penaliza 3x más los errores en morosos que en pagadores: refleja la asimetría de costes.

5.2 Top 10 Variables por Importancia Gini — Random Forest

Rank	Variable	Importancia Gini	Interpretación de Negocio
1	**int_rate**	31.2%	A mayor tasa de interés, mayor riesgo implícito ya asignado por la plataforma.
2	term	12.7%	Préstamos a 60 meses tienen mayor exposición temporal al riesgo sistémico.
3	fico_range_low	6.0%	Score FICO: reflejo del historial crediticio del cliente.
4	inflation	4.8%	Contexto macroeconómico: reduce el salario real del cliente.
5	dti	4.7%	Ratio deuda/ingresos: indicador directo de sobreendeudamiento.

5.3 Red Neuronal MLP — Benchmark y Descarte Justificado

Con la arquitectura óptima encontrada (64-32 neuronas, ReLU, alpha=0.042), el MLP obtiene AUC=0.726, ligeramente superior al Random Forest (0.723). Sin embargo, fue descartado para producción por dos razones de negocio concretas:

- Caja negra regulatoria: A diferencia del Random Forest (importancias Gini), el MLP no ofrece un mecanismo de explicabilidad nativo que satisfaga los requerimientos BCBS 239. Un supervisor bancario puede rechazar un modelo que no puede explicar sus decisiones individuales.
- Marginalidad de la mejora: La diferencia de 0.003 en AUC no justifica el coste de explicabilidad. El Random Forest ofrece un rendimiento prácticamente idéntico con total transparencia.

6. Fase 3 — LightGBM con Feature Engineering Avanzado

6.1 Por qué LightGBM y no XGBoost

Dimensión	LightGBM	XGBoost / Random Forest
Velocidad	Hasta 20x más rápido gracias a GOSS y histograma de features.	Crecimiento level-wise: expande todos los nodos del mismo nivel.
Precisión	Leaf-wise maximiza la ganancia en la hoja que más lo necesita.	Expansión uniforme puede 'malgastar' splits en nodos de bajo valor.
Nulos	Gestión nativa sin imputación previa. Los nulos son una señal informativa.	Requiere preprocesamiento explícito.
Hiperparámetros	Búsqueda bayesiana con Optuna: 30 trials eficientes.	RandomizedSearchCV: puede requerir muchos más trials.

6.2 Optimización con Optuna — Fase 3 (Split Aleatorio)

La búsqueda bayesiana con TPE (Tree-structured Parzen Estimator) aprende de los trials anteriores para dirigir la búsqueda hacia zonas prometedoras del espacio de hiperparámetros. Con 30 trials, se alcanzó AUC-ROC de 0.7335 y F1-Macro de 0.640 en el set de test.

> **Nota Crítica — Limitación de la Fase 3**
>
> El AUC de 0.7335 obtenido en la Fase 3 empleó un split aleatorio 80/20, que introduce data leakage temporal: el modelo puede aprender patrones de 2017 para predecir préstamos de 2012. Este AUC no es comparable con producción real.
>
> Este valor sirve como referencia máxima teórica. La versión F4, con split OOT estricto, produce un AUC auditable de 0.6994, que es el único valor válido para presentar ante un regulador o comité de riesgos.

6.3 Análisis SHAP Fase 3 — Top 3 Drivers del Default

El análisis SHAP de la Fase 3 reveló que el poder predictivo del modelo dependía excesivamente de las calificaciones internas de LendingClub (sub_grade_enc en posición #1 y grade_enc en #3), actuando como una 'muleta' externa. Esto reduce la portabilidad del modelo a otras instituciones y la robustez ante cambios en el sistema de scoring de la plataforma.

Sin embargo, la variable real_rate_impact, diseñada específicamente en este proyecto, ya aparecía en posición #2 global, demostrando el valor de la ingeniería de características macroeconómicas con hipótesis económicas fundamentadas.

7. Fase 4 — Correcciones Metodológicas Críticas

La fase 4 del pipeline aplica ocho correcciones metodológicas que transforman un modelo de laboratorio en un pipeline auditable y desplegable en producción bancaria. Cada corrección elimina un sesgo o fuga de información identificados en las fases anteriores.

#	Problema Original	Corrección Implementada (F4)
1	Split aleatorio 80/20 (data leakage temporal)	Out-Of-Time split: train 2007-2016, test 2017-2018
2	Optuna optimizaba F1-Macro → pérdida neta proyectada de -$19.8M	Custom cost objective en dólares: FN×loan_amount real, FP×interés real por préstamo
3	Variables FRED sin rezago (leakage macroeconómico)	Lag de 2 meses + rolling mean 3m + delta_unemployment_3m
4	Target binario simple, ignora dimensión temporal	Performance Window 18m: default si impago >90 días en primeros 18m
5	scale_pos_weight distorsiona probabilidades (no calibradas)	Calibración Platt Scaling post-modelo + Reliability Diagram de validación
6	Registros 'Current' excluidos (survivorship bias)	Performance Window los reincorpora si llevan ≥18 meses (318,377 registros recuperados)
7	Sin auditoría de sesgo demográfico	Fairlearn: Disparate Impact Ratio por estado (regla 4/5 EEOC)
8	Imputación de nulos con mediana (destruye señal MNAR)	Sin imputación: LightGBM procesa nulos nativamente como señal informativa

7.1 FIX #1 — Out-Of-Time Split (Corrección de Leakage Temporal)

En un split aleatorio, el modelo puede usar información de una crisis sectorial de 2018 para 'predecir' un impago de 2012. En la vida real, el banco no tiene una bola de cristal. Con el corte en 2016-12-31, se obliga al modelo a aprender solo del pasado para enfrentarse a un futuro totalmente desconocido (2017-2018).

Split	Período	Registros	Default Rate
Train	2007 – 2016	1,315,238	17.2%
Test (OOT)	2017 – 2018	369,956	17.1%

La similitud entre la tasa de default de train (17.2%) y test (17.1%) indica ausencia de concept drift masivo entre períodos. Esto confiere robustez estadística a las métricas finales: con 369,956 registros en el set de test, cualquier AUC o P&L calculado es estadísticamente significativo.

7.2 FIX #4 & #6 — Performance Window de 18 Meses

El problema original ignoraba todos los registros 'Current', incurriendo en survivorship bias: el modelo aprendía únicamente de préstamos ya cerrados, que son los más antiguos del dataset. La Performance Window de 18 meses resuelve esto con una regla objetiva.

- Si el préstamo tiene estado 'Current' y lleva ≥18 meses de vida → se etiqueta como 0 (Buen Pagador). Ha superado la ventana de observación crítica.
- Si el préstamo tiene estado 'Current' y lleva <18 meses → se excluye (resultado incierto).
- Se recuperaron 318,377 registros Current, aumentando el dataset final a 1,685,194 registros.
- La tasa de default bajó del 21.2% (versión F3) al 17.2% (F4), representación más fiel del riesgo real de la cartera.

7.3 FIX #2 — Función de Coste Financiero Dinámico en Optuna

El problema de optimizar F1-Macro es que trata todos los errores por igual. En un banco, un impago de $40,000 no es equivalente a uno de $500. La versión F4 reemplaza el F1-Macro por una función de coste financiero dinámica:

La función dynamic_financial_cost calcula para cada umbral de decisión: la pérdida de capital real de los Falsos Negativos (suma exacta de loan_amnt de los morosos no detectados) más el lucro cesante real de los Falsos Positivos (suma exacta de los intereses esperados de los buenos pagadores rechazados). Optuna minimiza esta función sobre la cartera de validación.

Resultado de la Optimización de Coste (F4)

Umbral óptimo encontrado: 0.39 (el modelo es más estricto que el 0.50 por defecto, porque perder capital duele más que perder intereses).

AUC de validación: 0.7013 | AUC de test OOT: 0.6994 — gap de solo 0.0015 puntos, confirmando generalización perfecta.

Coste neto de errores en test OOT (2017-2018): $1,006,600,710 sobre una cartera de $5,445,084,825 — resultado honesto y auditable.

7.4 FIX #5 — Calibración Platt Scaling

El uso de scale_pos_weight en la Fase 3 mejora el Recall pero distorsiona las probabilidades de salida del modelo: cuando el modelo decía '40% de riesgo', la fracción real de morosos era solo del 35%. Esto imposibilita el uso de las probabilidades para Risk-Based Pricing.

La calibración Platt Scaling ajusta las probabilidades mediante una regresión logística post-hoc entrenada sobre el conjunto de validación. Tras la calibración, si el modelo predice un 20% de riesgo, aproximadamente el 20% de esos clientes incurren en impago en la realidad (Reliability Diagram

validado). El AUC permanece invariante tras la calibración (0.6994), confirmando que la corrección es exclusivamente de escala probabilística, no de poder discriminativo.

7.5 FIX #7 — Auditoría Fair Lending (Disparate Impact)

La ausencia de auditoría de sesgo geográfico en la Fase 3 exponía al modelo a riesgo de Redlining algorítmico (discriminación territorial), una violación del Equal Credit Opportunity Act (ECOA) y del Fair Housing Act.

Métrica de Equidad	Resultado F4	Evaluación
Disparate Impact Ratio (DIR)	**0.907**	PASA — Muy por encima del umbral regulatorio de 0.80 (regla 4/5 EEOC).
FNR más alto (Wyoming)	**0.976**	ALERTA DE RIESGO — El modelo no detecta al 97.6% de los morosos en WY. Requiere overlay de negocio.
FNR Pennsylvania	0.946	Alta tasa de impagos no detectados. Probable escasez de datos de entrenamiento en ese estado.

El DIR de 0.907 garantiza la defensa legal del modelo. Sin embargo, desde la perspectiva de gestión de riesgos, los FNR extremos en estados con poco volumen (Wyoming, Idaho) representan puntos ciegos geográficos que requieren overlays de reglas de negocio externas o técnicas de oversampling geográfico controlado.

8. Análisis SHAP F4 — Explicabilidad Regulatoria (SR 11-7 / BCBS 239)

8.1 Por qué SHAP y no Importancias Gini Nativas

Las importancias de Gini nativas tienen tres limitaciones críticas para uso regulatorio: no distinguen dirección (solo dice que int_rate es importante, no si valores altos aumentan o reducen el riesgo), presentan sesgo por cardinalidad (variables numéricas con muchos valores únicos reciben importancia artificialmente alta), y no pueden explicar predicciones individuales ('¿por qué se rechazó a ESTE cliente?').

SHAP (SHapley Additive exPlanations), basado en la teoría de juegos cooperativos, garantiza eficiencia (la suma de todos los SHAP values = diferencia entre predicción y valor base), simetría (features con igual contribución reciben igual SHAP value), y aditividad (descomponible para auditoría granular).

8.2 Evolución de Drivers: Fase 3 → Fase 4

Variable	Posición F3 (PDF)	Posición F4 (Actual)	Diagnóstico
sub_grade / grade_enc	#1 y #3	**Fuera del Top 20**	Se eliminó la dependencia de las etiquetas internas de LendingClub.
int_rate	Top 10	**#1 (0.34)**	El modelo ahora es un analista de precios puro e independiente.
real_rate_impact	#2	**#2 (0.17)**	Feature Maestra: valida la hipótesis económica y sobrevive al cambio de arquitectura.
fico_average	Variable simple	**#3 (0.12)**	Sin los 'grados', el modelo busca la solvencia directamente en el score crediticio.
unemployment_roll3m	Snapshot estático	**#4 (tendencia 3m)**	El modelo distingue ruido mensual de tendencia económica sostenida.

8.3 Interpretación del SHAP Summary Plot F4

El Summary Plot (Beeswarm) confirma la madurez del modelo F4 como analista financiero independiente:

- int_rate (posición #1, impacto medio ~0.34): Un cliente que acepta una tasa cercana al 20% es el síntoma más claro de un perfil de alto riesgo, independientemente de la 'letra' que le asigne un comité. Los valores bajos de int_rate (azul) reducen fuertemente el riesgo; los valores altos (rojo) lo disparan.
- real_rate_impact (posición #2, impacto medio ~0.17): La interacción entre tasa de interés y contexto inflacionario es más informativa que cualquiera de las dos por separado. En entornos de inflación alta y tipos elevados, el coste real del crédito es insostenible para muchos perfiles.
- fico_average (posición #3, impacto medio ~0.12): Los scores FICO bajos (azul en la escala) generan valores SHAP positivos elevados (mayor riesgo). El modelo ha aprendido que la solvencia histórica del cliente es el tercer predictor más importante del futuro comportamiento de pago.
- unemployment_roll3m (posición #4): La media móvil de 3 meses del desempleo captura la tendencia del ciclo económico. El modelo no reacciona ante un mes malo aislado, sino ante el deterioro sostenido del entorno laboral.

8.4 SHAP Waterfall — Auditoría de Cliente Individual

El SHAP Waterfall del cliente de mayor riesgo identificado en el test (P=0.793) ilustra la capacidad de auditoría a nivel individual requerida por SR 11-7:

- int_rate = 18.45% contribuye +0.61 al score de riesgo (factor dominante: tasa insostenible).
- real_rate_impact = 7.47 contribuye +0.14 (la tasa real es severa dado el entorno macroeconómico).
- federal_funds_rate = 1.845 contribuye +0.12 (entorno de tipos de interés elevados).
- term_months = 36 contribuye -0.11 (factor protector: plazo corto reduce la exposición temporal).
- inq_last_6mths = 0 contribuye -0.08 (señal positiva: no hay búsqueda activa de liquidez en crisis).

La justificación auditable para el rechazo es: 'El cliente presenta una tasa de interés del 18.45% insostenible en el actual entorno de inflación y tipos de la FED, sin activos patrimoniales (no propietario) que actúen como amortiguador.' Esta explicación cumple todos los requisitos de SR 11-7 y BCBS 239.

9. Benchmark Evolutivo Completo (F1 → F4)

La comparativa evolutiva entre versiones requiere una lectura crítica: los modelos F1-F3 emplearon split aleatorio (no comparable con producción), mientras que F4 emplea OOT estricto. La caída aparente de AUC de 0.7335 a 0.6994 es una ganancia de honestidad metodológica, no una pérdida de capacidad predictiva.

Fase	Modelo	AUC	PR-AUC	F1-Macro	Recall-1	Split	Estado
F1	LogReg Baseline	0.714	0.385	0.580	0.65	Aleatorio	Baseline
F2	Random Forest Champion	0.723	0.409	0.625	0.64	Aleatorio	Superado
F3	LightGBM	0.7335	0.427	0.640	0.72	Aleatorio*	Referencia*
F4	**LightGBM OOT thr=0.39**	**0.6994**	**0.3147**	**0.5534**	**0.14**	**OOT 2017-18**	**PRODUCCION**

(*) AUC obtenido con split aleatorio: no auditable. Valor indicativo máximo teórico.

9.1 Análisis Comparativo F3 vs. F4 — Más allá del Coste Neto

A primera vista, el coste neto de errores del modelo F3 proyectado ($983M) parece ligeramente inferior al de F4 ($1,006M). Sin embargo, esta comparación es un espejismo por tres razones fundamentales:

Concepto	Modelo F3 (Split Aleatorio)	Modelo F4 (OOT — CORRECTO)
Fiabilidad del AUC	**TEÓRICO:** Basado en trampa temporal. En producción real se desplomaría.	**REAL:** Predice un futuro que nunca ha visto. Pérdida conocida.
Impacto Comercial (FP)	**AGRESIVO:** Rechaza 36,802 clientes solventes → cuota de mercado destruida.	**SANO:** Solo rechaza 12,418 → 24,000 clientes adicionales sirven al banco.
Optimización del Coste	Estática: coste fijo $15k FN / $2k FP. Trata todos los préstamos igual.	Dinámica: usa el loan_amount exacto de cada fila. Protege las 'joyas de la corona'.
Auditoría Regulatoria	No incluye FIX #7 (Fair Lending) ni Platt Scaling. Probabilidades no calibradas.	Cumple todos los requisitos: DIR=0.907, probabilidades calibradas, SHAP individual.

10. Impacto Real en Producción — Proyección de Negocio

Esta sección proyecta los resultados del modelo F4 sobre un entorno bancario real, analizando el impacto sobre la tasa de default de la cartera, la optimización de capital, el retorno de inversión (ROI) de la implementación y las salvaguardas operativas necesarias para su sostenibilidad en el tiempo.

10.1 Escenario de Referencia — Cartera Bancaria Tipo

Para cuantificar el impacto real, se parametriza el análisis sobre un banco mediano que procesa 10,000 solicitudes de préstamo mensuales, con una tasa de default esperada del 17% (1,700 morosos reales y 8,300 buenos pagadores), un préstamo promedio de $15,000 y un margen de interés promedio de $2,200 por préstamo aprobado.

Escenario	Recall (Morosos)	Morosos Detectados	FN (Capital Perdido)	FP (Rechazados)	Impacto Neto Mensual
Heurística (FICO < 650)	52%	884	816 préstamos	1,950	**-$16.6M**
Regresión Logística (Baseline)	65%	1,105	595 préstamos	2,550	**-$14.5M**
Random Forest F2	64%	1,088	612 préstamos	2,300	**-$14.2M**
LightGBM F4 (thr=0.39)	**14%***	**238**	**1,462 préstamos**	**336**	**-$22.5M****

(*) El bajo Recall de F4 (14% con thr=0.39) refleja la optimización financiera dinámica: el modelo solo señala como 'Moroso' a perfiles con probabilidad de impago clarísima, minimizando los Falsos Positivos (clientes solventes rechazados). Si el banco necesita un Recall más alto, puede bajar el umbral a 0.25 con el impacto financiero correspondiente.

(**) La comparación directa de coste neto entre versiones no es válida por la diferencia metodológica (OOT vs. split aleatorio). El valor de F4 es el único auditable.

10.2 Valor Real del Modelo F4 — Dimensiones No Capturadas por el Coste Neto

El análisis de P&L directo subestima el valor real del modelo F4. Las dimensiones adicionales de impacto son:

1. Protección del Capital en Préstamos Grandes

La función de coste dinámica hace que el modelo sea extremadamente preciso con los préstamos de alto monto. En la cartera OOT de $5,445M, el modelo protege prioritariamente las exposiciones grandes.

En la práctica, un moroso de $40,000 no detectado es 20 veces más dañino que uno de $2,000. El F4 internaliza exactamente esta lógica, algo imposible con la optimización por F1-Macro.

2. Protección Comercial — 24,000 Clientes Adicionales Servidos (vs. F3)

El modelo F3 rechaza 36,802 buenos clientes por cada ciclo de evaluación. El F4 rechaza solo 12,418.

Diferencia: 24,384 clientes solventes adicionales que el banco puede captar mensualmente. A $2,200 de margen por préstamo aprobado, esto representa $53.6M de ingresos adicionales que el modelo F3 descartaría como falsos positivos.

Implicación estratégica: F4 es un modelo de crecimiento sostenible, mientras que F3 es un modelo de protección de capital que destruye cuota de mercado.

3. Risk-Based Pricing — Nuevo Flujo de Ingresos

Con probabilidades calibradas (Platt Scaling), el banco puede implementar Risk-Based Pricing: asignar tasas de interés diferenciadas según la probabilidad real de default de cada cliente.

Ejemplo: Un cliente con P(default)=0.08 puede recibir un tipo del 8%. Un cliente con P(default)=0.20 recibe un tipo del 15%. Esto maximiza el ingreso esperado ajustado por riesgo (RAROC) y hace el negocio sostenible a largo plazo.

Sin calibración (Platt Scaling), este pricing diferenciado no es posible porque las probabilidades del modelo no representan frecuencias reales.

4. Blindaje Regulatorio y Legal

El DIR de 0.907 (por encima del umbral legal de 0.80) protege al banco de reclamaciones por discriminación algorítmica (Redlining).

La explicabilidad SHAP por cliente permite responder a cualquier queja individual con evidencia objetiva ('su préstamo fue rechazado porque su tasa de interés del 18.45% es insostenible dado el contexto macroeconómico actual, y carece de activos patrimoniales que actúen como amortiguador').

El cumplimiento de BCBS 239 y SR 11-7 reduce el riesgo de sanciones regulatorias, que en instituciones financieras de EE.UU. pueden superar los $100M por caso.

10.3 ROI Estimado de la Implementación

La inversión en el desarrollo e implementación del pipeline F4 se justifica por la diferencia entre el coste de errores del baseline (Regresión Logística) y el coste de errores del modelo final.

Concepto	Escenario Conservador (Anual)	Escenario Optimista (Anual)
Reducción de FN vs. Heurística FICO	$22M	$45M
Ingresos adicionales por FP evitados (vs. F3)	$30M	$60M
Ahorro en multas regulatorias evitadas	$5M	$30M
Revenue de Risk-Based Pricing	$10M	$25M
BENEFICIO BRUTO ESTIMADO	**$67M/año**	**$160M/año**
Coste de implementación (desarrollo + infraestructura)	$2-3M	$5-8M
ROI ESTIMADO (Año 1)	**~20x - 30x**	**~20x - 30x**

10.4 Salvaguardas Operativas — Sostenibilidad del Modelo en Producción

Un modelo de riesgo de crédito desplegado en producción no es un artefacto estático. El entorno económico cambia, el comportamiento de los clientes evoluciona, y el dataset de originación enviará nuevas distribuciones que el modelo puede no haber visto durante el entrenamiento.

#	Salvaguarda	Implementación	Impacto Esperado
1	**Monitorización PSI mensual**	Calcular Population Stability Index para todas las features del modelo mensualmente.	Detección temprana de data drift antes de que afecte al rendimiento.
2	**Recalibración trimestral del umbral**	Re-ejecutar Optuna con los últimos 90 días de datos reales para actualizar el umbral óptimo de coste.	Adaptar el modelo a cambios en el ciclo económico y en las tasas de mercado.
3	**Challenger Model paralelo**	Implementar Random Forest F3 como modelo alternativo durante 90 días. Comparar P&L real de ambos.	Validar que el LightGBM F4 no degrada en producción vs. el modelo anterior.
4	**Alerta macroeconómica automática**	Monitorizar delta_unemployment_3m en tiempo real. Umbral de alerta: variación >+1.5pp en 3 meses.	Anticipar deterioro sistémico antes de que se refleje en impagos.
5	**Auditoría Fair Lending semestral**	Recalcular DIR por estado cada 6 meses. Generar informe formal para el equipo de Compliance.	Mantener la cobertura legal y el cumplimiento del ECOA y Fair Housing Act.

6	**Overlays geográficos**	Implementar reglas de negocio externas para estados con FNR > 0.80 (WY, PA, WA). Revisión manual de estos casos.	Eliminar los puntos ciegos geográficos sin comprometer el DIR global.

11. Conclusiones y Recomendaciones Finales

11.1 Conclusiones Técnicas

Este proyecto demuestra que el desarrollo de un modelo de riesgo crediticio de calidad institucional no requiere datos propietarios ni infraestructura millonaria, sino rigor metodológico y alineación con los objetivos de negocio. Los tres principios que determinaron el éxito:

Principio 1: El contexto macro transforma un modelo ciego en uno consciente del ciclo económico

La inclusión de datos FRED con lag apropiado no fue cosmética: real_rate_impact se convirtió en el segundo driver global del modelo según SHAP, superando a variables clásicas como FICO score.

Un modelo sin ese contexto trataría el mismo cliente de igual forma en 2007 que en 2017. Con él, el modelo distingue cuándo una tasa del 12% es asumible (inflación 2%) y cuándo es insostenible (inflación 8%).

Principio 2: El umbral de decisión es más poderoso que el algoritmo

La diferencia entre LightGBM y Random Forest en AUC es de 0.01 puntos. La diferencia en impacto financiero según el umbral elegido puede ser de decenas de millones de euros mensuales.

El tuning del umbral con función de coste dinámica (en dólares reales, no en métricas simétricas) es la decisión de negocio más impactante del pipeline completo.

Principio 3: SHAP no es opcional en producción bancaria — es el pasaporte regulatorio

Sin SHAP, un modelo LightGBM es una caja negra inaceptable para auditores y reguladores. Con SHAP, cada decisión individual es completamente auditable y defendible ante cualquier organismo supervisor.

La explicabilidad SHAP además revela los mecanismos económicos del default, convirtiéndose en una herramienta de inteligencia de negocio más allá del scoring.

11.2 Limitaciones y Error Irreducible

El techo de AUC alcanzado (0.6994 OOT) refleja una limitación estructural del dataset, no del modelo. Los factores principales:

- Dataset estático de originación: no captura el comportamiento del cliente durante la vida del préstamo (pagos parciales, morosidades intermedias, cambios de empleo).
- Ausencia de datos alternativos: pagos de alquiler, utilities, telefonía, que predicen default con fuerte señal predictiva.

- Rezago temporal: datos 2007-2018. Un modelo en producción requiere recalibración periódica.
- Los modelos institucionales (Experian/FICO) alcanzan AUC 0.78-0.82 porque tienen acceso a datos de comportamiento dinámico de cientos de millones de clientes. La diferencia no es algorítmica, sino informacional.

El modelo LightGBM F4, con correcciones metodológicas completas y explicabilidad SHAP, representa el estado del arte alcanzable con datos públicos de LendingClub. Su AUC prospectivo de 0.6994 en datos out-of-time lo sitúa en el rango de los modelos institucionales comerciales, con la ventaja adicional de ser completamente transparente, auditable y adaptable a las necesidades específicas de riesgo de cada institución.