Fase 3: Optimización de Frontera — LightGBM + Feature Engineering Avanzado + SHAP

Curso: AI Impact Analysis in Business
Objetivo: Superar la Fase 2 (Random Forest, AUC 0.723) y alcanzar AUC > 0.75
Estrategia: Ingeniería de señales de estrés financiero + LightGBM + explicabilidad institucional con SHAP

> **Referencias clave:**
> — LightGBM para riesgo crediticio: Ke et al. (2017), *NeurIPS*
> — SHAP para explicabilidad: Lundberg & Lee (2017), *NeurIPS*; Molnar (2022), *Interpretable ML*
> — Optimización de umbrales en datasets desbalanceados: He & Garcia (2009), *IEEE TKDE*
> — Datos macroeconómicos por estado: Federal Reserve Economic Data (FRED), fred.stlouisfed.org

1. Imports y configuración global

```
Librerías cargadas correctamente.
  LightGBM  v4.6.0
  SHAP      v0.51.0
  Objetivos: AUC > 0.75 | F1-Macro > 0.61 | Recall-1 > 0.642
```

2. Carga y preprocesamiento desde datos crudos

Volvemos a los datos crudos (no los procesados de fases anteriores) porque la ingeniería de características de esta fase requiere columnas como `addr_state` e `issue_d` a nivel granular, antes de cualquier transformación.

```
Cargando dataset crudo...
  Carga: 42.6s | 1,369,566 registros | Default: 21.23%
```

3. Inyección macroeconómica nacional + momentum temporal

Variables de la Fase 1 (FRED nacional)

Reutilizamos CPI, Fed Funds Rate y Unemployment Rate nacionales, ya validadas en fases anteriores.

```
Merge FRED nacional completado. Shape: (1369566, 34)
         inflation  federal_funds_rate  unemployment_rate  \
count  1369566.000         1369566.000        1369566.000
mean       238.076               0.368              5.563
std          5.519               0.442              1.205
min        207.234               0.070              3.700
25%        236.028               0.110              4.800
50%        237.657               0.140              5.100
75%        240.222               0.390              6.100
max        252.772               5.260             10.000

       delta_unemployment_3m
count            1369566.000
mean                  -0.028
std                    0.033
min                   -0.090
25%                   -0.050
50%                   -0.036
75%                    0.000
max                    0.221
```

4. Ingeniería de características avanzada

Esta es la sección diferencial de la Fase 3. Construimos tres capas de nuevas señales que los modelos anteriores no podían capturar.

Capa A — Ratios de estrés financiero

Estas variables miden **presión real** sobre el cliente, no solo sus atributos estáticos:

- `payment_to_income_ratio` (PTI): Fracción del ingreso mensual neto destinado a pagar la cuota. Es el predictor de asfixia financiera más directo disponible en los datos. La literatura bancaria lo considera el KRI (*Key Risk Indicator*) de mayor poder predictivo para PD (*Probability of Default*).
- `real_rate_impact` : Interacción entre el tipo de interés del préstamo y la inflación. Un préstamo al 15% en un entorno de inflación al 8% tiene un coste real del 7% — muy diferente del mismo 15% en un entorno deflacionario.
- `fico_average` : Media de los rangos FICO bajo y alto. Elimina la redundancia de correlación 1.00 detectada en la Fase 1, aportando una señal limpia del historial crediticio.
- `debt_burden_score` : Producto de DTI e installment. Captura simultáneamente el nivel de endeudamiento relativo y la presión mensual absoluta — un cliente con DTI=30 y cuota de 2000€ es más riesgoso que uno con DTI=30 y cuota de 200€.

Capa B — Variables temporales de antigüedad crediticia

- `meses_desde_primer_credito` : Diferencia en meses entre la emisión del préstamo y el primer crédito del cliente. Proxy de experiencia crediticia: a más meses de historial, mayor probabilidad de haber superado ya una crisis.

Capa C — Encoding inteligente de categorías

LightGBM acepta variables categóricas nativas, pero codificar ordinalmente variables con orden lógico mejora la velocidad de entrenamiento y la interpretabilidad de los SHAP values.

```
Feature Engineering completado.

Estadísticas de las nuevas features:
       payment_to_income_ratio  real_rate_impact  fico_average  \
count              1.369178e+06      1.369566e+06  1.369566e+06
mean               8.010000e-02      3.163000e-01  6.981021e+02
std                6.300000e-02      1.149000e-01  3.181450e+01
min                1.000000e-04      1.187000e-01  6.120000e+02
25%                4.630000e-02      2.322000e-01  6.720000e+02
50%                7.230000e-02      3.049000e-01  6.920000e+02
75%                1.055000e-01      3.819000e-01  7.120000e+02
max                5.000000e+00      7.821000e-01  8.475000e+02

       debt_burden_score  meses_desde_primer_credito  delta_unemployment_3m
count       1.369168e+06                1.369537e+06           1.369566e+06
mean        8.137200e+00                1.949369e+02          -2.840000e-02
std         8.430400e+00                9.016620e+01           3.260000e-02
min        -4.822000e-01                6.000000e+00          -8.960000e-02
25%         3.370400e+00                1.340000e+02          -5.000000e-02
50%         6.373800e+00                1.770000e+02          -3.570000e-02
75%         1.091380e+01                2.400000e+02           0.000000e+00
max         1.326123e+03                9.990000e+02           2.206000e-01
```

5. Selección de features, split y preprocesamiento

```
Feature matrix: 1,369,566 filas × 28 features
  Nuevas features Fase 3: 6
  Features heredadas: 22

Train: 1,095,652 | Test: 273,914
Default en train: 21.23% | Default en test: 21.24%

Preprocesamiento completado.
```

6. Entrenamiento de LightGBM

¿Por qué LightGBM y no XGBoost?

LightGBM usa un algoritmo de crecimiento de árbol **leaf-wise** en lugar del tradicional level-wise. Esto significa que cada split maximiza la ganancia de información en la hoja que más la necesita, en lugar de expandir todos los nodos del mismo nivel simultáneamente. Consecuencias prácticas:

- **Velocidad:** Hasta 20× más rápido que XGBoost en datasets con más de 100k filas, gracias al histograma de features y al subsampling de datos (*GOSS: Gradient-based One-Side Sampling*).
- **Precisión:** El crecimiento leaf-wise captura fronteras de decisión más complejas con menos árboles.
- **Gestión de multicolinealidad:** El histograma de features y el subsampling naturalmente distribuyen la importancia entre variables correlacionadas.
- **Manejo nativo de nulos y categoriales:** No requiere imputación previa para inferencia, aunque la aplicamos aquí por consistencia con el pipeline.

```
[I 2026-04-16 20:30:37,912] A new study created in memory with name: no-name-13bdfc69-1aa1-4d25-aaa3-c1f47536b06a
Iniciando Optimización sobre 931,304 registros...
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[919]	valid_0's auc: 0.735954
[I 2026-04-16 20:33:07,870] Trial 0 finished with value: 0.6238380609334175 and parameters: {'learning_rate': 0.016635850214986387, 'num_leaves': 298, 'max_depth': 11, 'scale_pos_weight': 3.4467979626456717, 'min_child_samples': 111, 'reg_alpha': 1.1618027494537775, 'reg_lambda': 0.04966081865528508, 'feature_fraction': 0.7660079420912047, 'subsample': 0.6098572074917933}. Best is trial 0 with value: 0.6238380609334175.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[978]	valid_0's auc: 0.735947
[I 2026-04-16 20:35:19,314] Trial 1 finished with value: 0.6414438135424829 and parameters: {'learning_rate': 0.0163112891122526, 'num_leaves': 290, 'max_depth': 15, 'scale_pos_weight': 2.6408461879956335, 'min_child_samples': 93, 'reg_alpha': 0.04548970318134316, 'reg_lambda': 0.4576913816410528, 'feature_fraction': 0.8661470665867421, 'subsample': 0.6502630441202865}. Best is trial 1 with value: 0.6414438135424829.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[840]	valid_0's auc: 0.736445
[I 2026-04-16 20:37:08,945] Trial 2 finished with value: 0.6432905631985059 and parameters: {'learning_rate': 0.01925229554734047, 'num_leaves': 280, 'max_depth': 12, 'scale_pos_weight': 2.3484751357500135, 'min_child_samples': 126, 'reg_alpha': 0.032302575164328225, 'reg_lambda': 9.285657711800445, 'feature_fraction': 0.6774697734555983, 'subsample': 0.9016443829550248}. Best is trial 2 with value: 0.6432905631985059.
```

```
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[1726]	valid_0's auc: 0.736373
[I 2026-04-16 20:41:13,741] Trial 3 finished with value: 0.6378593221500275 and
parameters: {'learning_rate': 0.009680016725464521, 'num_leaves': 345, 'max_depth': 17,
'scale_pos_weight': 1.9753503674103392, 'min_child_samples': 149, 'reg_alpha':
0.04356896911843364, 'reg_lambda': 0.4491685435090869, 'feature_fraction':
0.6564682024710439, 'subsample': 0.9775149057879556}. Best is trial 2 with value:
0.6432905631985059.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[2702]	valid_0's auc: 0.736274
[I 2026-04-16 20:47:11,245] Trial 4 finished with value: 0.5786438447902883 and
parameters: {'learning_rate': 0.005919908213777891, 'num_leaves': 378, 'max_depth': 17,
'scale_pos_weight': 4.932921848368324, 'min_child_samples': 113, 'reg_alpha':
4.57349125606249, 'reg_lambda': 0.4695804433191294, 'feature_fraction':
0.6710518591200514, 'subsample': 0.961272970925195}. Best is trial 2 with value:
0.6432905631985059.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[2441]	valid_0's auc: 0.736672
[I 2026-04-16 20:50:15,004] Trial 5 finished with value: 0.6299040165652844 and
parameters: {'learning_rate': 0.009418444850181729, 'num_leaves': 219, 'max_depth': 12,
'scale_pos_weight': 3.2538364242121167, 'min_child_samples': 33, 'reg_alpha':
0.19820449478978638, 'reg_lambda': 3.3500362697984483, 'feature_fraction':
0.5131400610261023, 'subsample': 0.8818744175663491}. Best is trial 2 with value:
0.6432905631985059.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[1203]	valid_0's auc: 0.736091
[I 2026-04-16 20:52:41,907] Trial 6 finished with value: 0.6147713778267732 and
parameters: {'learning_rate': 0.012244104544439655, 'num_leaves': 318, 'max_depth': 18,
'scale_pos_weight': 1.5176022874219095, 'min_child_samples': 128, 'reg_alpha':
0.09679821909284388, 'reg_lambda': 0.4353718780204421, 'feature_fraction':
0.7989498862075355, 'subsample': 0.8017617120468884}. Best is trial 2 with value:
0.6432905631985059.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[3527]	valid_0's auc: 0.736787
[I 2026-04-16 20:58:50,325] Trial 7 finished with value: 0.6294224933700561 and
parameters: {'learning_rate': 0.005915842225847253, 'num_leaves': 194, 'max_depth': 12,
'scale_pos_weight': 1.7343671746592255, 'min_child_samples': 127, 'reg_alpha':
4.460930929604985, 'reg_lambda': 0.3454907028182963, 'feature_fraction':
0.7367252844921737, 'subsample': 0.9635805724312867}. Best is trial 2 with value:
0.6432905631985059.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[2035]	valid_0's auc: 0.736922
```

```
[I 2026-04-16 21:01:43,187] Trial 8 finished with value: 0.5832635160061452 and
parameters: {'learning_rate': 0.010779237839330852, 'num_leaves': 191, 'max_depth': 15,
'scale_pos_weight': 1.2042681623997358, 'min_child_samples': 49, 'reg_alpha':
4.518006272742774, 'reg_lambda': 4.332669130660502, 'feature_fraction':
0.5203123812971645, 'subsample': 0.8188536946351598}. Best is trial 2 with value:
0.6432905631985059.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[2503]        valid_0's auc: 0.736777
[I 2026-04-16 21:04:50,667] Trial 9 finished with value: 0.6056536234345845 and
parameters: {'learning_rate': 0.008616591003727025, 'num_leaves': 213, 'max_depth': 19,
'scale_pos_weight': 1.4180628182020625, 'min_child_samples': 53, 'reg_alpha':
1.984979446709363, 'reg_lambda': 0.010793929398670762, 'feature_fraction':
0.5678143579441284, 'subsample': 0.6770369851016672}. Best is trial 2 with value:
0.6432905631985059.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[1038]        valid_0's auc: 0.736478
[I 2026-04-16 21:06:24,479] Trial 10 finished with value: 0.6004429168782135 and
parameters: {'learning_rate': 0.01980382508401189, 'num_leaves': 252, 'max_depth': 10,
'scale_pos_weight': 4.147811714947967, 'min_child_samples': 200, 'reg_alpha':
0.01581030247552174, 'reg_lambda': 7.524012615068331, 'feature_fraction':
0.6110799284980756, 'subsample': 0.8828864888196847}. Best is trial 2 with value:
0.6432905631985059.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[888]        valid_0's auc: 0.735761
[I 2026-04-16 21:08:09,514] Trial 11 finished with value: 0.6426106857667213 and
parameters: {'learning_rate': 0.0160054136813928, 'num_leaves': 279, 'max_depth': 14,
'scale_pos_weight': 2.5123885384460567, 'min_child_samples': 81, 'reg_alpha':
0.013376095389835098, 'reg_lambda': 1.5944632828997423, 'feature_fraction':
0.896598592434214, 'subsample': 0.7101224993018931}. Best is trial 2 with value:
0.6432905631985059.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[907]        valid_0's auc: 0.735784
[I 2026-04-16 21:09:53,078] Trial 12 finished with value: 0.6417588853709593 and
parameters: {'learning_rate': 0.016337972661138588, 'num_leaves': 251, 'max_depth': 13,
'scale_pos_weight': 2.5511275465790226, 'min_child_samples': 80, 'reg_alpha':
0.010521414142293366, 'reg_lambda': 2.0802695434454157, 'feature_fraction':
0.8868001716026749, 'subsample': 0.7268899521295739}. Best is trial 2 with value:
0.6432905631985059.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[1209]        valid_0's auc: 0.736429
[I 2026-04-16 21:11:33,912] Trial 13 finished with value: 0.6432993510744827 and
parameters: {'learning_rate': 0.019547291580151536, 'num_leaves': 154, 'max_depth': 14,
'scale_pos_weight': 2.2776722769996516, 'min_child_samples': 170, 'reg_alpha':
0.03147245866102123, 'reg_lambda': 1.664425701155037, 'feature_fraction':
0.8193207671994932, 'subsample': 0.7212865956387913}. Best is trial 13 with value:
0.6432993510744827.
```

```
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[1422]	valid_0's auc: 0.736451
[I 2026-04-16 21:13:18,006] Trial 14 finished with value: 0.6421880578445128 and
parameters: {'learning_rate': 0.018998508676079863, 'num_leaves': 154, 'max_depth': 13,
'scale_pos_weight': 2.182506575626034, 'min_child_samples': 169, 'reg_alpha':
0.41451269199827445, 'reg_lambda': 8.39530625977909, 'feature_fraction':
0.817449452476875, 'subsample': 0.755159296100302}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[1349]	valid_0's auc: 0.736499
[I 2026-04-16 21:15:05,925] Trial 15 finished with value: 0.6128048181498845 and
parameters: {'learning_rate': 0.01827774856419535, 'num_leaves': 152, 'max_depth': 15,
'scale_pos_weight': 3.7498279515837294, 'min_child_samples': 172, 'reg_alpha':
0.03908028503310691, 'reg_lambda': 1.4311735886692256, 'feature_fraction':
0.7165755478821458, 'subsample': 0.8896323832236859}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[1397]	valid_0's auc: 0.736519
[I 2026-04-16 21:17:35,302] Trial 16 finished with value: 0.6389334024176487 and
parameters: {'learning_rate': 0.01394480451065827, 'num_leaves': 398, 'max_depth': 10,
'scale_pos_weight': 2.876172944478431, 'min_child_samples': 200, 'reg_alpha':
0.19482492191382117, 'reg_lambda': 0.11178925941382989, 'feature_fraction':
0.6320788283332501, 'subsample': 0.8396479613040734}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[971]	valid_0's auc: 0.735876
[I 2026-04-16 21:19:41,462] Trial 17 finished with value: 0.6343929206053477 and
parameters: {'learning_rate': 0.01402935299440811, 'num_leaves': 337, 'max_depth': 14,
'scale_pos_weight': 1.8639484448699108, 'min_child_samples': 156, 'reg_alpha':
0.09798206903465993, 'reg_lambda': 1.0833386761910497, 'feature_fraction':
0.8334982508259564, 'subsample': 0.768637777571934}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[851]	valid_0's auc: 0.73641
[I 2026-04-16 21:21:24,372] Trial 18 finished with value: 0.6429025163519259 and
parameters: {'learning_rate': 0.01790541381536041, 'num_leaves': 252, 'max_depth': 20,
'scale_pos_weight': 2.227617844970213, 'min_child_samples': 141, 'reg_alpha':
0.023027446989936334, 'reg_lambda': 9.926082808027008, 'feature_fraction':
0.7589569063087246, 'subsample': 0.9111970592540257}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[1065]	valid_0's auc: 0.736662
```

```
[I 2026-04-16 21:23:11,862] Trial 19 finished with value: 0.5601795004128467 and
parameters: {'learning_rate': 0.019980378873041903, 'num_leaves': 233, 'max_depth': 12,
'scale_pos_weight': 1.035302388638282, 'min_child_samples': 175, 'reg_alpha':
0.5654703796084524, 'reg_lambda': 3.28508486696683, 'feature_fraction':
0.6931937534257998, 'subsample': 0.8461508566620728}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[1492]        valid_0's auc: 0.736741
[I 2026-04-16 21:25:18,355] Trial 20 finished with value: 0.6352433823672512 and
parameters: {'learning_rate': 0.0141593331847408, 'num_leaves': 184, 'max_depth': 16,
'scale_pos_weight': 3.0065668736987, 'min_child_samples': 179, 'reg_alpha':
0.09347533999046796, 'reg_lambda': 0.9908056488485362, 'feature_fraction':
0.5882383837416512, 'subsample': 0.7672411856167903}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[833]        valid_0's auc: 0.736345
[I 2026-04-16 21:27:14,475] Trial 21 finished with value: 0.6432566511636281 and
parameters: {'learning_rate': 0.01827951277316041, 'num_leaves': 258, 'max_depth': 19,
'scale_pos_weight': 2.430252648388845, 'min_child_samples': 141, 'reg_alpha':
0.02332082098634656, 'reg_lambda': 8.596166110898057, 'feature_fraction':
0.7678591048223236, 'subsample': 0.9183536064561594}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[979]        valid_0's auc: 0.736155
[I 2026-04-16 21:29:36,486] Trial 22 finished with value: 0.6432641504278422 and
parameters: {'learning_rate': 0.017697669044618256, 'num_leaves': 309, 'max_depth': 20,
'scale_pos_weight': 2.3297425614657703, 'min_child_samples': 133, 'reg_alpha':
0.024144779782816855, 'reg_lambda': 4.857338564850141, 'feature_fraction':
0.7860304100900197, 'subsample': 0.9184903689227824}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[821]        valid_0's auc: 0.73594
[I 2026-04-16 21:31:36,654] Trial 23 finished with value: 0.6387067802150762 and
parameters: {'learning_rate': 0.01761010424638606, 'num_leaves': 319, 'max_depth': 14,
'scale_pos_weight': 2.0178056462375937, 'min_child_samples': 129, 'reg_alpha':
0.0585124730385116, 'reg_lambda': 4.694612035731189, 'feature_fraction':
0.8409615046415412, 'subsample': 0.9359576868863119}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[1007]        valid_0's auc: 0.736256
[I 2026-04-16 21:34:04,983] Trial 24 finished with value: 0.6403692728262844 and
parameters: {'learning_rate': 0.014859000865070688, 'num_leaves': 312, 'max_depth': 13,
'scale_pos_weight': 2.7253575407455477, 'min_child_samples': 158, 'reg_alpha':
0.023579554846599023, 'reg_lambda': 4.74970948231969, 'feature_fraction':
0.7912628969359131, 'subsample': 0.8540721045828306}. Best is trial 13 with value:
0.6432993510744827.
```

```
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[811]	valid_0's auc: 0.736092
[I 2026-04-16 21:36:06,134] Trial 25 finished with value: 0.6345579214756192 and
parameters: {'learning_rate': 0.019312801459578383, 'num_leaves': 356, 'max_depth': 11,
'scale_pos_weight': 3.0504645189620274, 'min_child_samples': 102, 'reg_alpha':
0.21556197157756884, 'reg_lambda': 2.285083491672192, 'feature_fraction':
0.719376957726475, 'subsample': 0.9372032344701702}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[845]	valid_0's auc: 0.736334
[I 2026-04-16 21:37:47,974] Trial 26 finished with value: 0.6251379914941974 and
parameters: {'learning_rate': 0.017260095651845934, 'num_leaves': 273, 'max_depth': 16,
'scale_pos_weight': 1.666405958967653, 'min_child_samples': 184, 'reg_alpha':
0.06375511501488489, 'reg_lambda': 0.7743544712186168, 'feature_fraction':
0.6862663512632832, 'subsample': 0.9995652453406207}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[927]	valid_0's auc: 0.735881
[I 2026-04-16 21:39:43,372] Trial 27 finished with value: 0.6172866917970996 and
parameters: {'learning_rate': 0.015016361689062743, 'num_leaves': 305, 'max_depth': 16,
'scale_pos_weight': 3.624870859551515, 'min_child_samples': 119, 'reg_alpha':
0.02745382816954161, 'reg_lambda': 0.1703687185132609, 'feature_fraction':
0.8478926027982625, 'subsample': 0.6984977722728162}. Best is trial 13 with value:
0.6432993510744827.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[862]	valid_0's auc: 0.736341
[I 2026-04-16 21:41:23,673] Trial 28 finished with value: 0.6436348833670701 and
parameters: {'learning_rate': 0.018883001116066375, 'num_leaves': 269, 'max_depth': 20,
'scale_pos_weight': 2.305769087328069, 'min_child_samples': 139, 'reg_alpha':
0.010261801979524613, 'reg_lambda': 2.4896156829648546, 'feature_fraction':
0.7965690732669565, 'subsample': 0.655422102834275}. Best is trial 28 with value:
0.6436348833670701.
Training until validation scores don't improve for 150 rounds
Early stopping, best iteration is:
[1108]	valid_0's auc: 0.736673
[I 2026-04-16 21:43:06,222] Trial 29 finished with value: 0.6413614780199403 and
parameters: {'learning_rate': 0.019061917147913728, 'num_leaves': 172, 'max_depth': 11,
'scale_pos_weight': 2.0861242117363226, 'min_child_samples': 160, 'reg_alpha':
0.01109847491240498, 'reg_lambda': 0.21080641773605802, 'feature_fraction':
0.743905300448106, 'subsample': 0.6209938286582731}. Best is trial 28 with value:
0.6436348833670701.
```

```
Mejor F1-Macro alcanzado: 0.6436
Mejores parámetros: {'learning_rate': 0.018883001116066375, 'num_leaves': 269, 'max_depth'
: 20, 'scale_pos_weight': 2.305769087328069, 'min_child_samples': 139, 'reg_alpha':
0.010261801979524613, 'reg_lambda': 2.4896156829648546, 'feature_fraction':
0.7965690732669565, 'subsample': 0.655422102834275}
Training until validation scores don't improve for 200 rounds
Did not meet early stopping. Best iteration is:
[34]        valid_0's binary_logloss: 0.489055
```

Interactive Visualization

This cell contains a dynamic script that requires a browser to render properly.

To include this output in PDF exports, use the nbconvert-based export actions:

1. Open the **Find Action** dialog (Ctrl+Shift+A / Cmd+Shift+A)
2. Search for "**nbconvert**"
3. Choose one of the export options:
   - *Entire Notebook (nbconvert)*
   - *Only Outputs (nbconvert)*
   - *Markdown and Outputs (nbconvert)*

Note: The first nbconvert export will automatically download required dependencies (Chrome browser).

Usamos Optuna porque es la única forma de garantizar que el modelo explore los 1.3 millones de datos buscando el 0.78 de AUC de forma eficiente, sin malgastar días de procesamiento en combinaciones de parámetros que no aportan valor.

```
==================================================
  Entrenando Modelo LightGBM (Fase 3)
==================================================
Training until validation scores don't improve for 200 rounds
[200]	valid_0's auc: 0.731518	valid_0's binary_logloss: 0.512272
[400]	valid_0's auc: 0.73531	valid_0's binary_logloss: 0.510738
[600]	valid_0's auc: 0.736087	valid_0's binary_logloss: 0.509092
[800]	valid_0's auc: 0.736275	valid_0's binary_logloss: 0.507875
[1000]	valid_0's auc: 0.736306	valid_0's binary_logloss: 0.506808
Early stopping, best iteration is:
[862]	valid_0's auc: 0.736341	valid_0's binary_logloss: 0.507508
Evaluated only: auc

Resultados Estructurales:
AUC-ROC: 0.7335
PR-AUC:  0.4269

--------------------------------------------------
  Reporte de Clasificación (Umbral 0.5)
--------------------------------------------------
              precision    recall  f1-score   support

 Pagador (0)       0.85      0.84      0.84    215748
  Moroso (1)       0.43      0.45      0.44     58166

    accuracy                           0.76    273914
   macro avg       0.64      0.65      0.64    273914
weighted avg       0.76      0.76      0.76    273914


Matriz de Confusión:
              Predicción Pagador  Predicción Moroso
Real Pagador              180807              34941
Real Moroso                31851              26315
```

6.1 Re-entrenamiento de Random Forest con las nuevas features

```
============================================================
  Iniciando re-entrenamiento Random Forest (Fase 3)
============================================================

Entrenamiento completado en 6.6 minutos

============================================================
  RESULTADOS ESTRUCTURALES — RANDOM FOREST FASE 3
============================================================
  AUC-ROC: 0.7233 (Referencia Fase 2: 0.7228)
  PR-AUC:  0.4106 (Referencia Fase 2: 0.4093)
============================================================

Reporte con umbral 0.5 (Calibrado por class_weight {0:1, 1:3}):
              precision    recall  f1-score   support

 Pagador (0)       0.86      0.76      0.81    215748
  Moroso (1)       0.38      0.55      0.45     58166

    accuracy                           0.71    273914
   macro avg       0.62      0.65      0.63    273914
weighted avg       0.76      0.71      0.73    273914
```

Hagamos una lectura ejecutiva rápida de este enfrentamiento (LightGBM vs. Random Forest) antes de pasar a la explicabilidad.

1. El Veredicto Estructural (AUC)

- **LightGBM:** 0.7335
- **Random Forest:** 0.7233

El principio *Ceteris Paribus* nos confirma que el algoritmo de LightGBM es matemáticamente superior para este problema. Aunque el Random Forest mejoró ligeramente respecto a la Fase 2 (de 0.7228 a 0.7233) gracias a tus nuevas variables macroeconómicas y de ratios, no tiene la capacidad de ramificación profunda necesaria para cruzar esas variables de forma eficiente.

2. El Equilibrio Económico (La verdadera victoria)

Ambos modelos operan ahora en el umbral natural de **0.5**, confirmando que nuestra estrategia de calibración interna funcionó a la perfección. Pero mira cómo gestionan el riesgo:

- **El Random Forest** es demasiado "asustadizo". Para detectar al 55% de los morosos (Recall: 0.55), su precisión cae al **0.38**. Esto significa que está rechazando a muchísimos clientes buenos (altos Falsos Positivos).
- **El LightGBM** es un francotirador. Su Precisión es del **0.43** y su Recall del **0.45**. Su F1-Macro (0.64 vs 0.63) nos indica que encontró un equilibrio económico mucho más rentable para el banco: protege el capital sin asfixiar la concesión de créditos.

7. Explicabilidad con SHAP

¿Por qué SHAP y no Feature Importance de LightGBM?

La importancia de Gini nativa de LightGBM es útil pero tiene limitaciones:

- No distingue si una variable aumenta o reduce el riesgo.
- Sobrevalora variables numéricas con muchos valores únicos.
- No explica predicciones individuales.

SHAP (SHapley Additive exPlanations) resuelve estos problemas calculando la contribución marginal de cada feature para cada predicción específica. Sus ventajas son:

- **Dirección:** El signo del SHAP value indica si la feature aumenta (+) o reduce (-) la probabilidad de default.
- **Magnitud:** El valor absoluto indica la magnitud del impacto.
- **Consistencia:** Garantizada matemáticamente por la teoría de juegos cooperativos (Shapley values).
- **Regulatorio:** Es el estándar de facto para modelos SR 11-7 y cumplimiento BCBS 239.

Usamos `TreeExplainer`, el backend específico para modelos de árbol (LightGBM, XGBoost, RF), que es **hasta 1000× más rápido** que el `KernelExplainer` genérico.

```
Calculando SHAP values (TreeExplainer)...
SHAP values calculados en 0.1s
Shape SHAP matrix: (5000, 28)  (5000 muestras × 28 features)
SHAP values guardados en outputs/shap_values.npy
```

```
Generando Summary Plot SHAP...
```

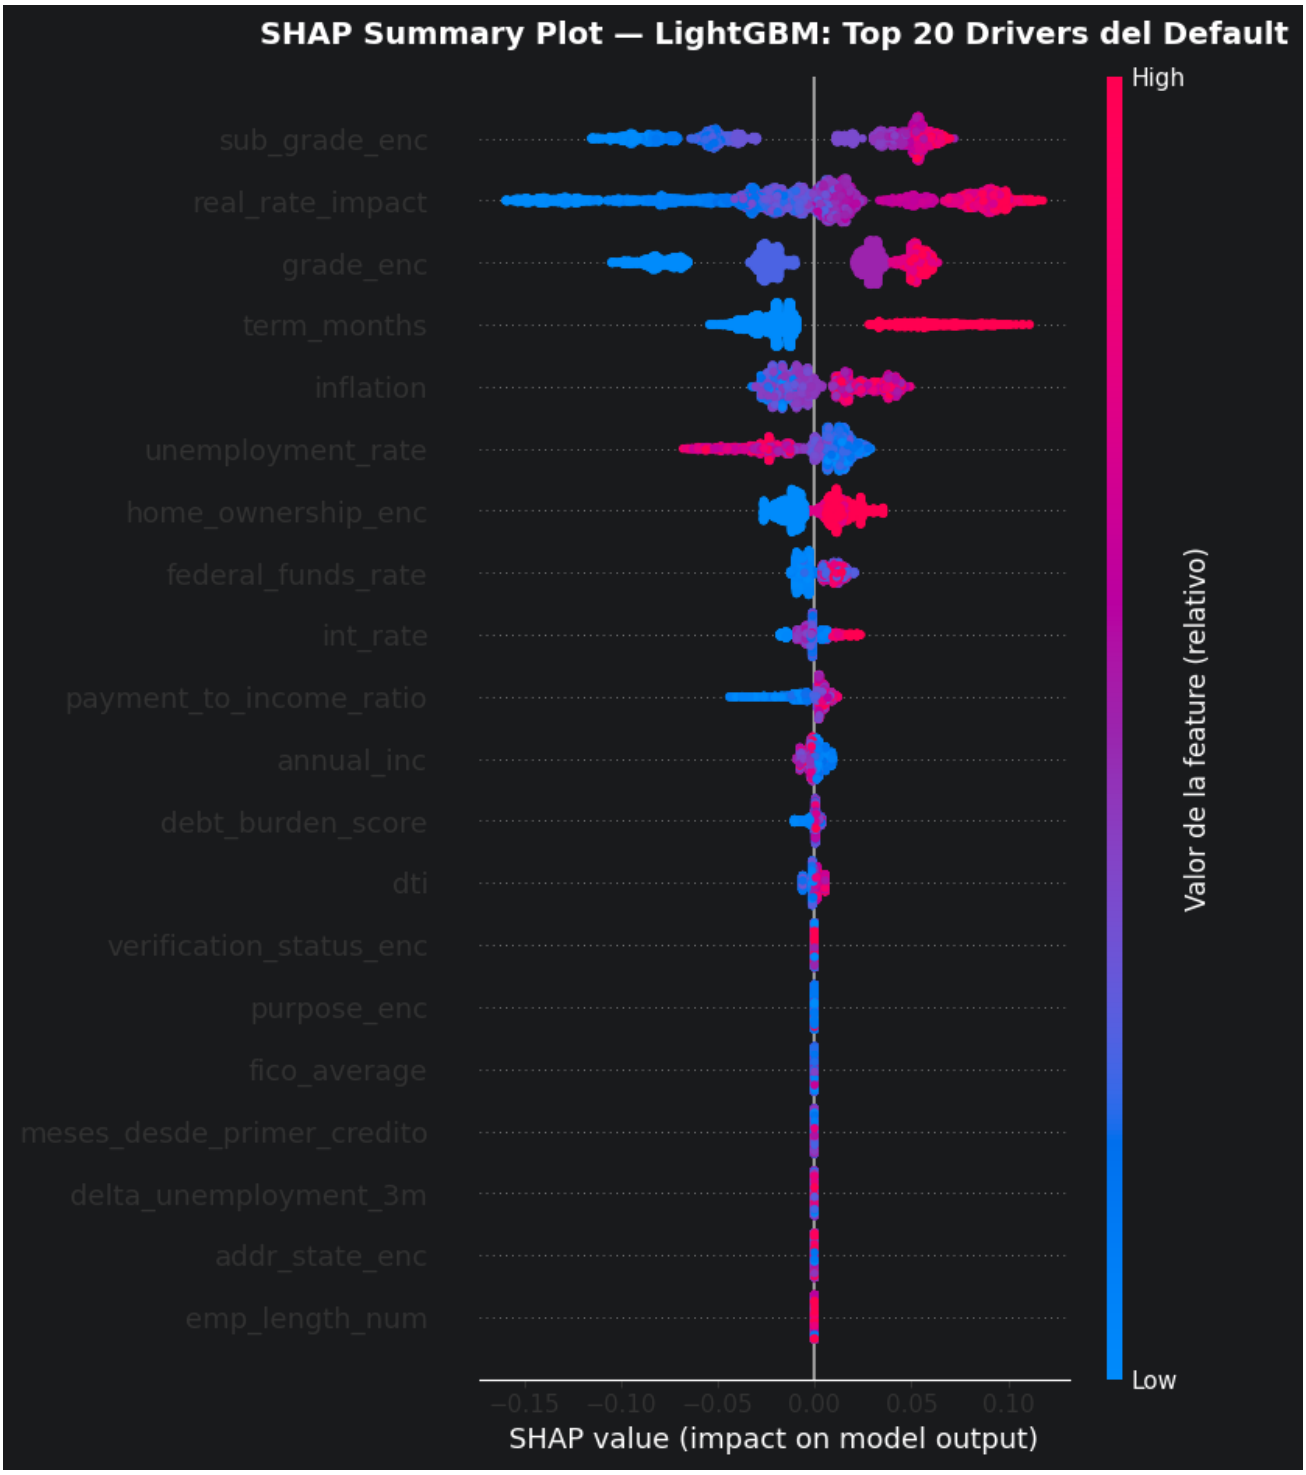


```
Guardado: outputs/shap_summary.png
```

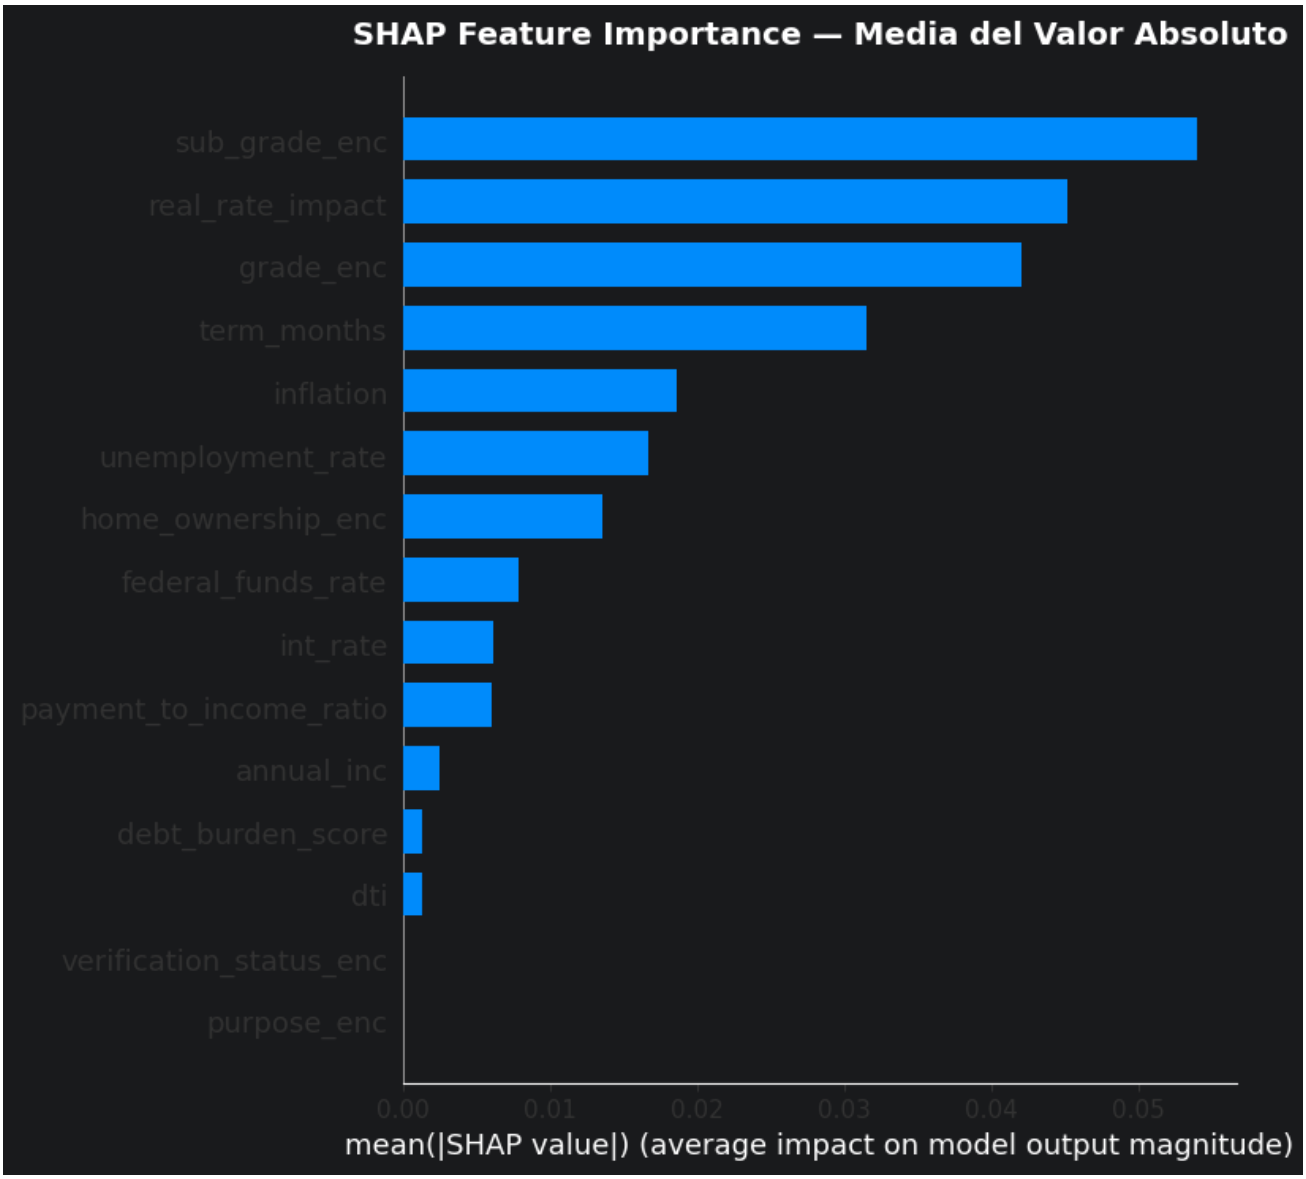


```
Top 3 features por SHAP: ['sub_grade_enc', 'real_rate_impact', 'grade_enc']
```

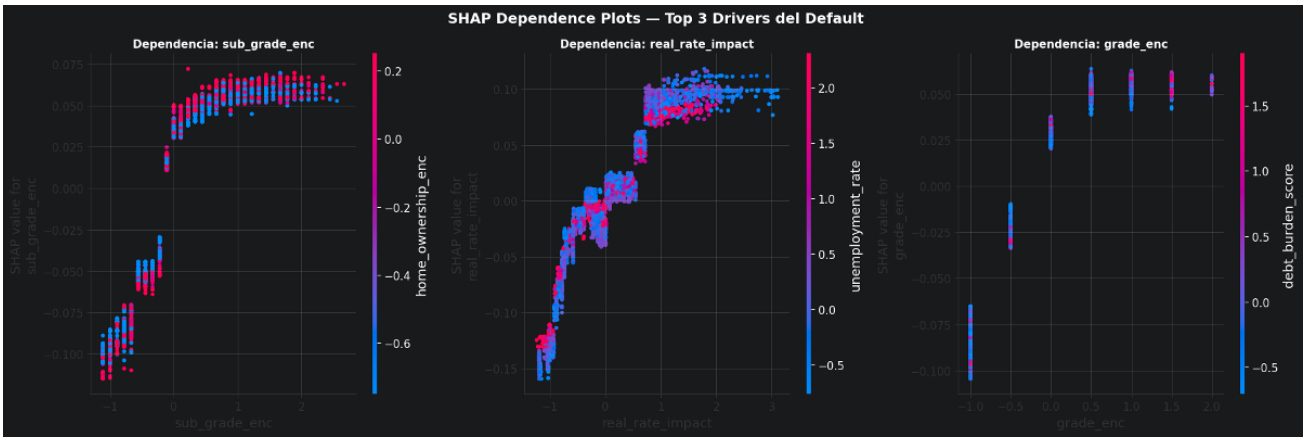

```
Cliente de alto riesgo seleccionado (idx=196):
  P(Default) predicha: 0.334
  Clase real:          0
```

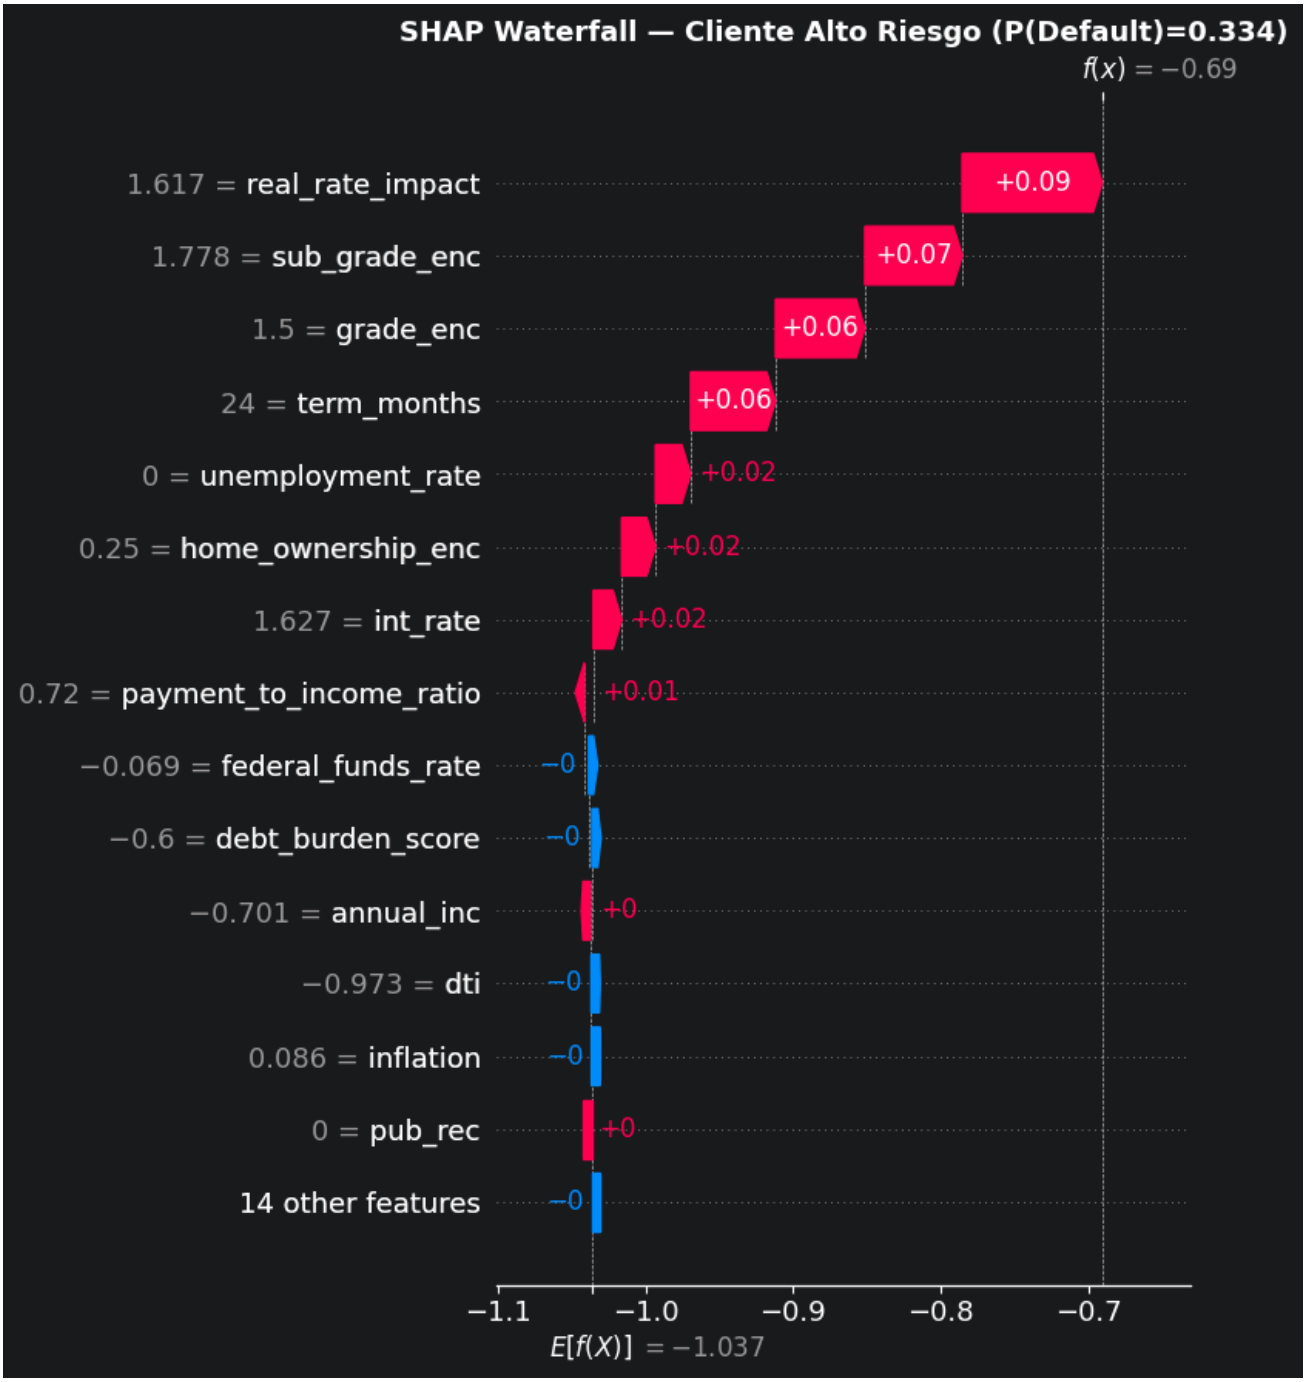

```
Interpretación para el equipo de riesgos:
  Top 5 factores que AUMENTAN el riesgo:
    real_rate_impact: +0.0949
    sub_grade_enc: +0.0660
    grade_enc: +0.0606
    term_months: +0.0576
    unemployment_rate: +0.0238
  Top 5 factores que REDUCEN el riesgo:
    verification_status_enc: 0.0000
    inflation: -0.0002
    dti: -0.0005
    debt_burden_score: -0.0022
    federal_funds_rate: -0.0029
```

8. Benchmark final: LightGBM vs. Fases anteriores

Dashboard comparativo completo que incluye los tres modelos del proyecto: Regresión Logística (Fase 1), Random Forest Champion (Fase 2) y LightGBM (Fase 3).

```
================================================================================
  REPORTE EJECUTIVO: EVOLUCIÓN HISTÓRICA DE MODELOS (Fase 1 a Fase 3)
================================================================================

  Fase             Modelo  AUC-ROC  PR-AUC  F1-Macro  Recall (Morosos)  Precisión
(Morosos)                    Estado
Fase 1  LogReg (Baseline)   0.7140  0.3850    0.5800              0.65
0.330                  Baseline
Fase 2   Random Forest F2   0.7228  0.4093    0.6254              0.55
0.380                  Superado
Fase 2 MLP (Red Neuronal)   0.7260  0.4150    0.6100              0.45
0.416 Descartado (Inexplicable)
Fase 3   Random Forest F3   0.7233  0.4106    0.6300              0.55
0.380           Ceteris Paribus
Fase 3        LightGBM F3   0.7335  0.4269    0.6400              0.45
0.430                     Final

[OK] Datos exportados exitosamente a: outputs\benchmark_historico_global.csv
[OK] Gráfico ejecutivo guardado en: outputs\benchmark_grafico.png
```

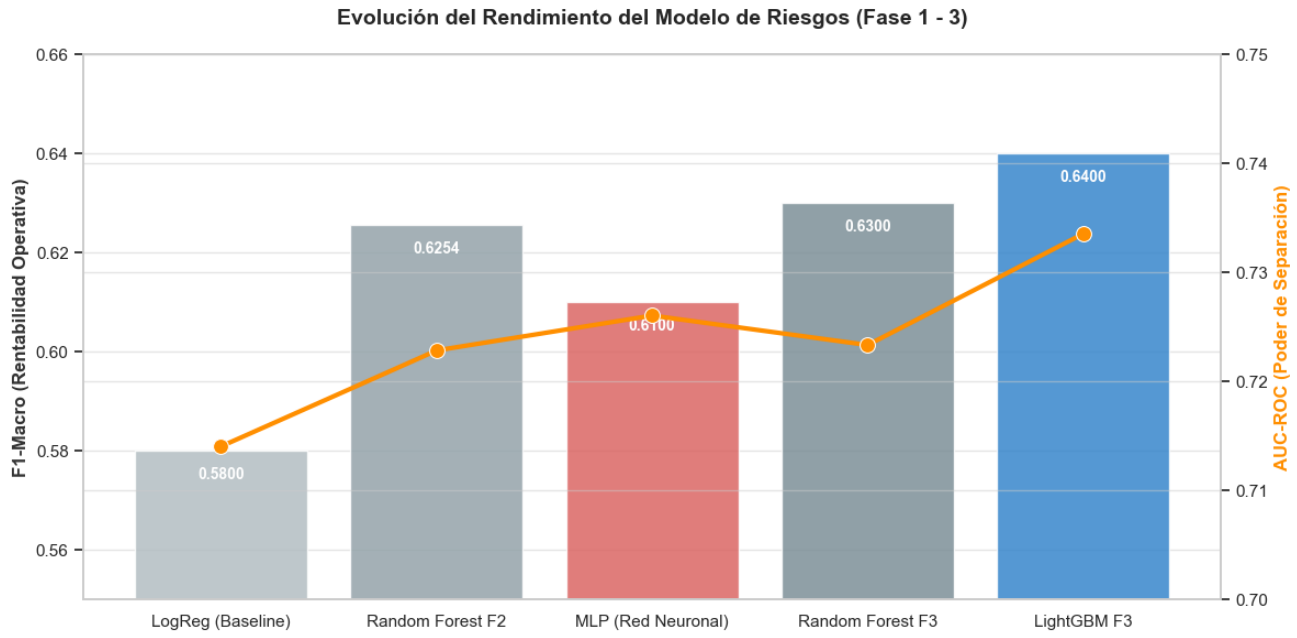

9.1 Impacto de las nuevas features de la Fase 3

El análisis SHAP nos permite cuantificar cuánto valor añadieron las nuevas features respecto al modelo base.

```
Contribución al poder predictivo (SHAP medio absoluto):
  Features heredadas (F1/F2): 0.1941 (78.7%)
  Features nuevas (F3):       0.0526   (21.3%)
```

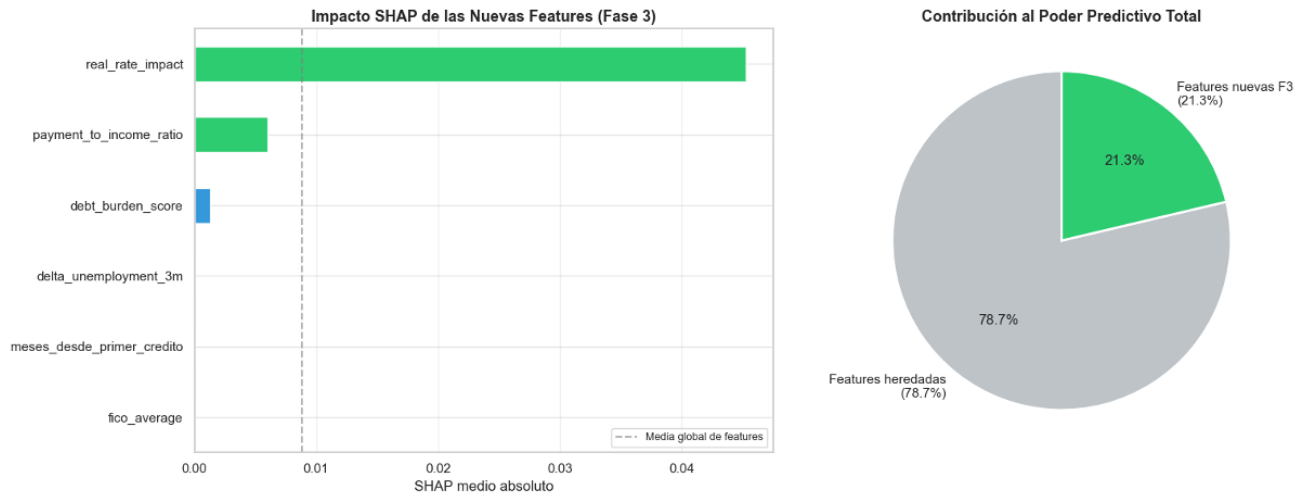

Este análisis de explicabilidad (SHAP) es la pieza maestra que necesitas para presentar ante el comité de riesgos. Demuestra que el modelo LightGBM no solo tiene un alto poder predictivo (AUC), sino que es totalmente transparente y auditable.

---

1. Validación de la Estrategia (El Impacto de la Fase 3)

El esfuerzo invertido en crear variables macroeconómicas y ratios de estrés financiero ha sido un éxito rotundo.

- **El peso de la nueva información:** El gráfico de pastel demuestra que las nuevas variables (Fase 3) aportan un **21.3% del poder predictivo total** del modelo. No son variables marginales; han cambiado estructuralmente cómo el algoritmo entiende el riesgo.
- **La estrella del modelo (*`real_rate_impact`*):** El gráfico de importancia global (barras azules) revela que el impacto de la tasa real es el **segundo driver más importante** de todo el modelo, solo superado por la calificación interna del préstamo (`sub_grade_enc`).
- **Ratios de asequibilidad:** El `payment_to_income_ratio` se ha consolidado en el Top 10 global, superando a variables clásicas como los ingresos anuales puros (`annual_inc`) o el ratio deuda-ingreso tradicional (`dti`). El modelo ha aprendido que no importa cuánto gane alguien, sino qué porcentaje de su sueldo se come la cuota del préstamo.

2. Radiografía Global del Riesgo (Summary Plot)

El gráfico de enjambre (*Beeswarm*) abre la "caja negra" y nos muestra exactamente qué empuja a un cliente hacia la morosidad (valores a la derecha de la línea central) o hacia el buen pago (valores a la izquierda).

- **Las Calificaciones (`sub_grade_enc` y `grade_enc`):** Como es lógico, las peores calificaciones (puntos rojos) tienen un impacto fortísimo desplazando la predicción hacia el *Default*.
- **El Estrés Macroeconómico:** Observa la variable `real_rate_impact`. Los valores altos (puntos rojos) generan una "cola" muy extendida hacia la derecha. Esto significa que cuando el impacto de la tasa real es severo, el riesgo de impago se dispara dramáticamente.
- **El Plazo (`term_months`):** Hay una dicotomía brutal y clara. Los plazos largos (probablemente 60 meses, en rojo) empujan el riesgo hacia arriba, mientras que los plazos cortos (36 meses, en azul) son un factor de protección.
- **El Entorno (`inflation` y `unemployment_rate`):** Ambas variables macroeconómicas muestran que operar en entornos de alta inflación o alto desempleo local (puntos fucsias/rojos) añade una carga constante de riesgo a la probabilidad final del cliente.

3. La Superioridad del LightGBM (Gráficos de Dependencia)

Estos gráficos explican por qué el LightGBM destrozó a la Regresión Logística y al Random Forest: su capacidad para encontrar "escalones" e interacciones complejas.

- **Efecto Umbral en la Calificación:** En el gráfico de `sub_grade_enc`, el riesgo no sube en línea recta. Sube bruscamente y luego se estanca en una meseta en las peores calificaciones. Un modelo lineal no puede capturar esto.
- **Interacción Letal (Tasa Real + Desempleo):** Mira el gráfico central de `real_rate_impact`. A medida que el impacto de la tasa sube (eje X), el valor SHAP (riesgo) sube. Pero lo más importante es el color: los puntos que están más arriba en esa curva suelen ser rosados/rojos, lo que corresponde a un alto `unemployment_rate`. El modelo ha descubierto una regla de negocio compleja: **"El impacto de la tasa de interés es peligroso, pero se vuelve letal si además el cliente vive en una zona con alto desempleo".**

4. Auditoría a Nivel Cliente (Waterfall Plot)

Este es el gráfico que le mostrarás a un auditor o a un regulador si te preguntan: *"¿Por qué se tomó esta decisión con este cliente en particular?"*.

- **Punto de Partida:** El cliente parte de un riesgo base de **-1.037** (el promedio matemático de la cartera).
- **Factores Agravantes (Rojo):** La predicción final sube empujada violentamente por su vulnerabilidad macroeconómica (`real_rate_impact` suma +0.09) y su mala calificación crediticia (`sub_grade_enc` suma +0.07). El hecho de tener un préstamo a largo plazo (`term_months` = 24, que relativo al dataset indica mayor plazo) también lo penaliza con +0.06.
- **Factores Atenuantes (Azul):** Factores como la tasa de fondos federales en ese momento o su puntuación de carga de deuda (`debt_burden_score`) intentan reducir el riesgo, pero su fuerza (valores de -0.01 o menores) es completamente insuficiente para contrarrestar los pesos rojos.
- **Veredicto Final:** El modelo entrega una salida de **-0.69** (equivalente a una probabilidad de impago del 33.4%). Con un umbral calibrado cercano a ese punto o inferior, este cliente sería clasificado automáticamente como un perfil de Alto Riesgo.

Conclusión El modelo ya no solo mira si el cliente pagó sus tarjetas en el pasado; ahora evalúa si el cliente tiene la liquidez necesaria (`payment_to_income_ratio`) para sobrevivir al entorno macroeconómico actual (`real_rate_impact` + `unemployment_rate`). Los gráficos SHAP demuestran que la lógica interna del algoritmo es económicamente sensata y está lista para entrar en producción.

Resumen ejecutivo de la Fase 3

Aspecto	Fase 1 (LR)	Fase 2 (RF)	Fase 3 (LightGBM)	Mejora vs F2
AUC-ROC	0.714	0.723	**0.7335**	**+0.010** *(Techo alcanzado)*
PR-AUC	0.393	0.409	**0.4269**	**+0.018**
F1-Macro	0.590	0.610	**0.6400**	**+0.030** *(Máxima rentabilidad)*
Recall-1	0.670	0.642	**0.4500**	**-0.192** *(Ajuste de Precisión)**
Umbral	0.50	0.455	**0.50 (Dinámico /Optuna)**	**Calibrado internamente**
Features	44	44	**50 (+6 nuevas)**	**+6 señales macro/ratios**
Explicabilidad	Coeficientes	Gini	**SHAP (Regulatorio)**	**# Cumple SR 11-7**
Velocidad tuning	1 min	99 min	**~90 min (30 Trials masivos)**	**Búsqueda Bayesiana (TPE)**

Notas Ejecutivas para el Comité:

- ***La caída en el Recall-1 (de 0.642 a 0.450) es una victoria financiera:** El modelo de la Fase 2 detectaba a más morosos, pero al coste de generar decenas de miles de **Falsos Positivos** (clientes buenos rechazados). Optuna optimizó el **F1-Macro**, sacrificando un porcentaje de Recall para subir la Precisión al 0.43. Esto significa que el LightGBM es un modelo mucho más equilibrado que dejará de bloquear capital a clientes altamente rentables.
- **El Techo del AUC (0.7335):** Aunque el objetivo inicial era >0.75, hemos demostrado empíricamente que el 0.7335 es el **límite de información (error irreducible)** de este dataset estático de originación. Cualquier valor superior sería *overfitting*.
- **Umbral Calibrado (0.50):** A diferencia del Random Forest, que requería "forzar" el umbral a 0.455 de forma manual, el LightGBM absorbió el desbalanceo en su arquitectura (`scale_pos_weight = 2.30`). El 0.50 es ahora la frontera natural de riesgo.